



INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DO AMAZONAS
CAMPUS MANAUS ZONA LESTE
BACHARELADO EM ENGENHARIA DE SOFTWARE

Rafael Moutinho Kanda

**USO DA INTELIGÊNCIA ARTIFICIAL PARA IDENTIFICAR O PERFIL DE
GESTANTES PROPENSAS A ABANDONAR O PRÉ-NATAL**

Manaus – AM

2025

RAFAEL MOUTINHO KANDA

**USO DA INTELIGÊNCIA ARTIFICIAL PARA IDENTIFICAR O PERFIL DE
GESTANTES PROPENSAS A ABANDONAR O PRÉ-NATAL**

Trabalho de Conclusão de Curso apresentado ao Curso Superior de Bacharelado em Engenharia de Software do Instituto Federal de Educação, Ciência e Tecnologia do Amazonas - *Campus* Manaus Zona Leste como requisito parcial à obtenção do título de Bacharel em Engenharia de Software.

Orientador: Prof. Mestre Benevaldo Pereira Gonçalves

Manaus – AM

2025

RAFAEL MOUTINHO KANDA

**USO DA INTELIGÊNCIA ARTIFICIAL PARA IDENTIFICAR O PERFIL DE
GESTANTES PROPENSAS A ABANDONAR OS EXAMES PRÉ-NATAL**

Trabalho de Conclusão de Curso apresentado ao Curso Superior de Bacharelado em Engenharia de Software do Instituto Federal de Educação, Ciência e Tecnologia do Amazonas - *Campus* Manaus Zona Leste como requisito parcial à obtenção do título de Bacharel em Engenharia de Software.

Aprovado em 08 de janeiro de 2025.

BANCA EXAMINADORA

Prof. Me. Benevaldo Pereira Gonçalves

Prof. Me. Paulo Sérgio Ruiz Del Aguila

Prof. Dr. David Brito Ramos

Manaus – AM

2025

DEDICATÓRIA

À minha mãe, ao meu pai e minha irmã.

AGRADECIMENTOS

À Deus pelas infinitas bênçãos concedidas a mim diariamente.

Aos meus familiares, especialmente, minha mãe, Kátia Kely, meu pai, Jorge Kanda, minha irmã, Beatriz Moutinho, e ao gato Astrobardo pelo amor incondicional.

Ao Prof. Benevaldo Pereira Gonçalves, pelas suas orientações ao longo do desenvolvimento deste Trabalho de Conclusão de Curso.

Aos demais professores do curso de Engenharia de Software do Instituto Federal de Educação, Ciência e Tecnologia do Amazonas - *Campus* Manaus Zona Leste pelos ensinamentos ministrados nas disciplinas.

A todos os colegas do curso pela convivência, colaborações e troca de conhecimentos.

Aos técnicos administrativos em educação do *Campus* Manaus Zona Leste do Instituto Federal de Educação, Ciência e Tecnologia do Amazonas por buscarem proporcionar um ambiente propício para o aprendizado.

Aos agentes terceirizados que por meio da execução de seus serviços tornaram o ambiente mais acolhedor e seguro.

RESUMO

O pré-natal é um conjunto de consultas e exames realizados durante a gravidez indispensável para garantir a segurança da mãe e de seu(s) bebê(s). Ainda que existam uma série de vantagens associadas, muitas grávidas abandonam ou até mesmo nem iniciam um acompanhamento de pré-natal, o que pode acarretar diversos riscos facilmente evitados com a realização das visitas a um profissional da saúde. Sabendo disso, este trabalho teve como objetivo criar um modelo de Inteligência Artificial com abordagem não-supervisionada para identificar o perfil de gestante que abandona o pré-natal. O modelo criado poderia ser usado por profissionais e unidades de saúde como uma ferramenta na busca ativa das grávidas que encaixem nesse perfil. Para isso, foi desenvolvido um aplicativo para *Android* com a finalidade de realizar a coleta de dados, que podem ser usados pelo modelo de aprendizado. Foram aplicados os algoritmos de agrupamento *K-means*, DBSCAN e GMM, além do uso das redes neurais *Autoencoder* e SOMs, visando a melhoria dos dados de entrada. Os resultados dos experimentos computacionais mostraram uma tendência na formação dos agrupamentos como consequência de apenas uma única característica informada, impedindo a manifestação das demais *features* necessárias para identificar o grupo propenso ao abandono do pré-natal. Dentre as principais contribuições deste trabalho está a construção de um aplicativo para auxiliar gestantes em sua gravidez e a apresentação de um conjunto de etapas para modelagem de algoritmos não-supervisionados.

Palavras-chave: Aplicativo. Aprendizado de máquina. Aprendizado não-supervisionado. Gravidez.

ABSTRACT

Prenatal care is a set of medical appointments and examinations carried out during pregnancy, essential to guarantee the safety of the mother and her baby(ies). Even though there are several associated advantages, many pregnant women abandon or even do not start prenatal care, which can lead to several risks easily avoided by visiting a healthcare professional. Knowing this, the present work aimed to create an Artificial Intelligence model with an unsupervised approach to identify the profile of pregnant women who abandon prenatal care. The model created could be used by health professionals and units as a tool in the active search for pregnant women with this profile. For this purpose, an Android application was developed to collect data, which can be used by the learning model. The K-means, DBSCAN and GMM clustering algorithms were applied, in addition to the Autoencoder and SOMs neural networks that were implemented to improve the input data. The results of the computational experiments showed a tendency in the formation of clusters as a consequence of just one single characteristic reported, preventing the manifestation of the other features necessary to identify the group prone to abandoning prenatal care. Among the main contributions of this work is the construction of an application to assist pregnant women in their pregnancy and the presentation of a set of steps for modeling unsupervised algorithms.

Keywords: Application. Machine learning. Unsupervised learning. Pregnancy.

LISTA DE FIGURAS

Figura 1 – Etapas do ciclo de vida de <i>machine learning</i>	31
Figura 2 – Metodologia	31
Figura 3 – Tela do <i>login</i>	36
Figura 4 – Tela principal	37
Figura 5 – Telas de controle de consultas, exames e vacinas	38
Figura 6 – Tela de gestação e plano de parto	39
Figura 7 – Tela do plano de parto detalhado e expectativas para o parto	40
Figura 8 – Telas do perfil	41
Figura 9 – Matriz de correlação entre variáveis	44
Figura 10 – Método do cotovelo e coeficiente <i>silhouette</i> usando <i>K-means</i>	47
Figura 11 – Critérios AIC e BIC do modelo GMM	48
Figura 12 – Resultado do <i>K-means</i>	50
Figura 13 – Resultado com DBSCAN	50
Figura 14 – Resultado com GMM	51
Figura 15 – Resultado com o <i>Autoencoder</i> + <i>K-means</i>	52
Figura 16 – Resultado com o <i>Autoencoder</i> + DBSCAN	52
Figura 17 – Resultado com o <i>Autoencoder</i> + GMM	53
Figura 18 – Resultado com o SOM + <i>K-means</i>	53
Figura 19 – Resultado com o SOM + DBSCAN	54
Figura 20 – Resultado com o SOM + GMM	54
Figura 21 – Aplicando o <i>NearestNeighbors</i> para descobrir o valor de <i>eps</i>	56
Figura 22 – Resultado com o DBSCAN atualizado	57
Figura 23 - Valor de <i>eps</i> com os dados do <i>Autoencoder</i> a partir do <i>NearestNeighbors</i>	58
Figura 24 - Resultados com <i>Autoencoder</i> + DBSCAN atualizado	58
Figura 25 - Resultado com o SOM + <i>K-means</i> atualizado	59
Figura 26 - Resultado com o SOM + GMM atualizado	60

LISTA DE QUADROS

Quadro 1 – Tipos de atributos	25
Quadro 2 – Principais trabalhos de machine learning aplicado em gravidez	29
Quadro 3 – <i>Dataset</i> gerado	42

LISTA DE TABELAS

Tabela 1 - Número de gestantes por quantidade de consultas pré-natal em 2023 e 2024	13
Tabela 2 – Porcentagem de consultas pré-natal por idade (2008-2019)	15
Tabela 3 – Exemplo do resultado da padronização dos valores do <i>dataset</i>	43
Tabela 4 – Balanceamento dos registros por valor de atributo	45
Tabela 5 – Escalonamento das características	45
Tabela 6 – Qualidade do agrupamento de cada algoritmo medido por <i>SilhouetteScore</i>	55
Tabela 7 – Taxa de ruídos nos dados identificados pelos modelos originais e aperfeiçoados..	60
Tabela 8 – Avaliação da qualidade do agrupamento gerado por diferentes algoritmos	61
Tabela 9 – Quantidade de elementos em cada cluster	61
Tabela 10 – Média dos valores de cada coluna filtrados por cluster	62

SUMÁRIO

1 INTRODUÇÃO	12
1.1 Objetivo Geral	14
1.2 Objetivos Específicos	14
1.3 Justificativa	14
2 REFERENCIAL TEÓRICO	16
2.1 <i>Android</i>	16
2.2 <i>Flutter</i>	18
2.3 <i>Sklearn</i>	19
2.4 <i>Python</i>	20
2.5 <i>Machine Learning</i>	21
2.5.1 APRENDIZADO SUPERVISIONADO	23
2.5.2 APRENDIZADO NÃO SUPERVISIONADO	24
2.5.3 TIPOS DE ATRIBUTOS	25
2.6 IA na Saúde	25
2.7 Gravidez e a Importância do Pré-Natal	26
2.8 Gravidez e o uso de <i>Machine Learning</i>	28
3 Metodologia	31
3.1 Delimitação do Tema	32
3.2 Escolha do <i>Dataset</i>	32
3.3 Tratamento do <i>Dataset</i>	33
3.4 Escolha do Algoritmo	33
3.5 Treinamento do Modelo	33
3.6 Teste do Modelo	34
3.7 Aperfeiçoamento do Modelo	34
3.8 Avaliação do Modelo	34
4 RESULTADOS	35
4.1 Delimitação do Tema	35
4.2 Escolha do <i>Dataset</i>	35
4.3 Tratamento do <i>Dataset</i>	43
4.4 Escolha do Algoritmo	46

4.5 Treinamento do Modelo	47
4.5.1 <i>K-means</i>	47
4.5.2 DBSCAN	48
4.5.3 GMM	48
4.5.4 Rede Neural <i>Autoencoder</i>	49
4.5.5 SOMs	49
4.6 Teste do Modelo	49
4.6.1 <i>K-means</i>	49
4.6.2 DBSCAN	50
4.6.3 GMM	51
4.6.4 Rede Neural Autoencoder	51
4.6.5 SOMs	53
4.7 Aperfeiçoamento do Modelo	54
4.7.1 DBSCAN	56
4.7.2 SOMs	58
4.8 Avaliação do Modelo	61
5 CONSIDERAÇÕES FINAIS	63
REFERÊNCIAS	67

1 INTRODUÇÃO

O desenvolvimento tecnológico é um aspecto revolucionário, capaz de modificar toda a sociedade. A Revolução Industrial, por exemplo, transformou uma sociedade extremamente manual e artesanal em uma com o estímulo ao mercado, barateamento dos custos e produção em massa. O mesmo ocorre com as novas tecnologias, elas são integradas no dia a dia, modificando o que já existe, extinguindo ou até criando novas coisas.

Uma das grandes tecnologias do momento é a Inteligência Artificial (IA), que possui o objetivo de fazer as máquinas “pensarem” como humanos, ou seja, serem capazes de fazer tarefas com inteligência, com a habilidade de perceber, aprender, adaptar e melhorar. Ao contrário do senso comum, que muitas vezes relaciona a IA como um robô senciente, como mostrado em filmes, as aplicações e utilizações da mesma são diversas e extremamente comuns. Sua utilidade estende-se em inúmeros campos, tais como: previsões de tempo, filtros de spam, seleção de anúncios, indicações de conteúdo, sistemas de vigilância, reconhecimento facial, automatização de ambientes, entre outros. Com uma tecnologia tão versátil, foram surgindo diversas pesquisas para aplicá-la de forma mais eficiente e melhorar processos já existentes, uma das áreas afetadas é a medicina (Soares *et al.*, 2023).

Um dos grandes usos da IA na saúde está no reconhecimento de imagens, identificando problemas que o paciente pode ter, sendo também usado no auxílio da saúde mental para verificação de indícios de depressão (Kaufman, 2022). Embora tenha seus benefícios, ainda existem algumas questões que impactam o amplo uso dessa tecnologia, tais como os aspectos éticos e a dificuldade de relacionar os dados com os objetivos em questão. Apesar disso, há diversos meios para utilizar a Inteligência Artificial em prol da melhoria da saúde da população de forma que não tenha tantas consequências e impactos, como o problema abordado neste trabalho.

O problema explorado neste trabalho está relacionado a um acontecimento comum na sociedade: a gestação. Mesmo sendo um fenômeno cotidiano, a falta de cuidados adequados pode levar a uma série de riscos para toda a família, por isso, é preciso que haja um acompanhamento durante todo o processo de gravidez, realizando os exames pré-natal. Segundo o Ministério da Saúde (Brasil, 2024b), o objetivo dos exames pré-natal é garantir o desenvolvimento saudável da gestação, diminuindo os riscos associados ao parto tanto para a mãe quanto para o bebê. Durante a gravidez, recomenda-se que a mãe realize, no mínimo, seis consultas, aumentando a frequência conforme vai aproximando o momento do parto. Desse modo, o acompanhamento é uma etapa fundamental para permitir que a gestante e o bebê permaneçam com saúde e segurança durante e após esse longo processo.

Sabendo disso, é fundamental garantir que as grávidas façam os exames pré-natal com o maior número de visitas possível ao profissional da saúde, porém isso não acontece na realidade de muitas mães. De acordo com o Relatório de Pré-Natal na Atenção Básica (Brasil, 2024c), disponível no Sistema de Informação em Saúde para a Atenção Básica (SISAB), o número de gestantes no Brasil que busca atendimentos pré-natal tem reduzido ao longo dos meses do ano de 2024. A Tabela 1 mostra o número de gestantes no que procuram atendimento pré-natal no Brasil nos anos de 2023 e 2024.

Tabela 1 - Número de gestantes por quantidade de consultas pré-natal em 2023 e 2024.

Ano	Mês	De 1 a 3 atendimentos	De 4 a 5 atendimentos	6 ou mais atendimentos
2024	Outubro	9424	108	20
	Setembro	10455	507	194
	Agosto	13038	1266	686
	Julho	15684	2375	1634
	Junho	19601	3579	3577
	Maiο	25365	5671	6983
	Abril	42627	11445	18187
	Março	63981	18355	38337
	Fevereiro	76334	21884	51156
	Janeiro	89117	24991	62492
2023	Dezembro	64128	17948	45794
	Novembro	79280	23030	56754
	Outubro	85549	24200	61075
	Setembro	80383	22844	57825
	Agosto	93504	26885	67483
	Julho	80679	23658	59435
	Junho	75618	22191	55108
	Maiο	85272	25056	61493
	Abril	72027	21191	51116
	Março	93471	27593	66092
	Fevereiro	73516	21867	53192
	Janeiro	92360	27571	66909

Fonte: Sistema de Informação em Saúde para a Atenção Básica - SISAB (Brasil, 2024c).

Nota: Data da última carga dos dados: 24/11/2024, estando sujeito a alterações.

Percebe-se que em todos os meses dos últimos anos, o número de gestantes que tiveram apenas de 1 a 3 atendimentos supera a quantidade de mães que buscaram ter um acompanhamento do profissional da área da saúde com mais frequência (a partir de seis atendimentos). Tal resultado demonstra que é necessária uma atuação para melhorar esse cenário. Salienta-se que, muito provavelmente, essa realidade não ideal tende ainda ser mais agravada em municípios localizados na Região Amazônica, onde existem uma série de dificuldades que podem impactar nos números de consultas, entre elas podem ser destacadas: a distância da unidade de saúde, desinformação, situação de vulnerabilidade socioeconômica, entre outros.

Diante deste contexto, a questão norteadora deste trabalho de conclusão do curso consiste em: qual o perfil de gestante com maior propensão ao abandono do pré-natal? Para responder tal indagação, foram estabelecidos os objetivos descritos a seguir.

1.1 Objetivo Geral

Criar um modelo de Inteligência Artificial para identificar o perfil de gestante que abandona o pré-natal.

1.2 Objetivos Específicos

- Coletar dados relevantes de gestantes e normalizá-los para garantir a consistência e uniformidade;
- Explorar técnicas de machine learning e selecionar aquela com maior adequação à natureza dos dados;
- Treinar e otimizar o modelo de inteligência artificial.

1.3 Justificativa

Analisando a problemática sob o escopo do estado do Amazonas, conforme já mencionado anteriormente, podem existir aspectos particulares de grande relevância que influenciam a quantidade reduzida de consultas buscadas pelas gestantes, principalmente para aquelas que habitam em áreas localizadas no interior do estado. As residentes de tais localidades geralmente enfrentam problemas com a infraestrutura, logística e acesso à informação, que contribuem para a dificuldade das mulheres serem acompanhadas nas consultas e na realização de exames pré-natal.

É importante considerar também que, devido às diversas situações sociais e econômicas, a probabilidade de engravidar mais cedo é maior nos municípios do interior em comparação com cidades grandes. Assim, ao relacionar a idade com questões de maturidade, desinformação, além dos outros problemas já mencionados aumenta muito as chances de abandono dos exames pré-natal.

Goes, Ramos e Ferreira (2023) relataram que, no período de 2008 a 2019, cerca de 25,4% dos nascidos vivos de mães adolescentes foram provenientes da Região Norte, sendo este valor composto por 1,5% de mães com idade de 10 a 14 anos, e 23,9% de mulheres que tinham de 15 a 19 anos no momento do parto. A distribuição dos valores relativos ao número de consultas pré-natal realizadas pelas gestantes dessas faixa etárias pode ser conferida na Tabela 2.

Tabela 2 – Porcentagem de consultas pré-natal por idade (2008-2019).

Número de consultas pré-natal	De 10 a 14 anos	De 15 a 19 anos
Nenhuma	3,3%	2,5%
De 1 a 3 consultas	13,9%	10,2%
De 4 a 6 consultas	38,2%	34,2%
7 ou mais consultas	43,6%	52,2%
Ignorado	1,0%	0,8%
Total	100,0%	100,0%

Fonte: Goes, Ramos e Ferreira (2023).

Conforme observado, há uma relação perceptível entre as mais jovens e a diminuição da quantidade de visitas para consultas. Enquanto mais da metade das adolescentes de mais idade realizam sete ou mais consultas de pré-natal, a maioria das adolescentes mais novas busca no máximo seis atendimentos durante a sua gravidez. À medida que mais detalhes vão sendo levados em consideração, é possível traçar relações que levam a menos visitas, o que se torna muito perigoso para essas mulheres, aumentando as chances de ocorrer problemas, até fatais, tanto para as mães quanto para os bebês.

Assim, elaborar uma maneira eficaz de analisar as características e identificar os perfis de gestantes propensas ao abandono dos exames pré-natal é uma atividade importante já que permite encontrar e propor métodos capazes de garantir um atendimento médico de qualidade e proporcionar segurança àquelas que mais necessitam.

Esta monografia está estruturada em cinco capítulos. O primeiro capítulo introdutório contém a questão norteadora, os objetivos e as justificativa do trabalho. O segundo capítulo é constituído pela fundamentação teórica, no qual são apresentados conceitos e características de termos relacionados ao tema desenvolvido. A descrição dos aspectos da metodologia adotada está detalhada no terceiro capítulo. Os principais resultados computacionais gerados pelos modelos de aprendizado de máquina, bem como as avaliações de desempenho desses modelos, estão expostos no quarto capítulo. E, finalmente, o quinto capítulo é composto pelas considerações finais com a exposição das principais conclusões obtidas neste trabalho, além das limitações enfrentadas e sugestões de trabalhos futuros.

2 REFERENCIAL TEÓRICO

2.1 *Android*

O *Android* é uma plataforma de software de código aberto para dispositivos móveis que consiste em um sistema operacional com acesso gratuito mantido pelo *Google* (Gandhewar; Sheikh, 2010). Essa característica possibilita que diferentes fabricantes consigam desenvolver uma grande quantidade de aparelhos com elevada capacidade de funcionalidade, pois o sistema operacional aberto ajuda a promover um ambiente altamente colaborativo entre seus integrantes, sendo um dos principais motivos para os desenvolvedores escolherem esse sistema (Steffen, 2020). O *Android* possui uma arquitetura baseada em Linux e com isso consegue aproveitar vários recursos, como gerenciamento de memória, processos, automatização de rede e drivers (Gandhewar; Sheikh, 2010).

Android tem atraído um amplo número de desenvolvedores e empresas de software. Steffen (2020) destaca que as condições de um ecossistema onde qualquer desenvolvedor pode colaborar, atrelado à popularidade do *Android*, são fundamentais para o impulsionamento do desenvolvimento de aplicativos (*apps*). Estes aplicativos quando usados por pessoas tendem a transformar, de certo modo, a sociedade na qual as novas indústrias e formas de trabalho devem se adaptar à nova realidade. Os *apps* são disponibilizados por uma indústria de aplicativos *mobile* constituída por: empresas que criam seus negócios a partir de aplicativos; empresas tradicionais que contratam desenvolvedores *mobile*; e companhias que desenvolvem aplicativos para outras empresas (Steffen, 2020).

O sistema operacional Android permite que *apps* sejam instalados em um *smartphone* para a execução de diferentes atividades, tais como: uso da calculadora, acesso a mapas das cidades e visualização das condições do tráfego em tempo real. O mundo do *smartphone* é constituído por indústrias de hardware, software e conectividade de ambos. Em cada uma dessas indústrias existem negócios que envolvem aspectos econômicos e sociais para os quais o *Android* contribui de forma direta. Em 2019, dentro do ecossistema de *smartphones*, a plataforma *Android* contribuiu para uma geração de receita estimada em R\$ 136 bilhões nas empresas diretamente envolvidas, que representa aproximadamente 2% do PIB brasileiro desse mesmo ano. Isso sem considerar que nas indústrias relacionadas ao *Android* há cerca de 630 mil postos de trabalho, o que corresponde a quase 35% dos trabalhadores na indústria de tecnologia e telecomunicações (Steffen, 2020). Além da popularidade do *smartphone* que tende a impulsionar o interesse de novos programadores pelo *Android*, a preferência por essa plataforma está diretamente relacionada aos recursos que oferece aos novos interessados em

programação, como por exemplo: ferramentas de apoio para o desenvolvimento, disposição de tecnologia *Open Source* e publicação beta.

Para quem deseja entrar no mundo da programação, é inevitável não ir em busca de conhecimento e aprendizado sobre o *Android*. De acordo com Steffen (2020), 78% dos desenvolvedores começam sua caminhada com o *Android*, até porque essa plataforma não deixa de ser importante durante a carreira profissional. Outro dado apresentado por esse mesmo autor, revela que entre os desenvolvedores brasileiros, 73% consideram o *Android* como a principal plataforma para desenvolvimento; 80% deles trabalham com *Android* e 60% com iOS; e o tempo total dedicado de programação é de 66% ao *Android* e 26% do tempo à plataforma iOS.

A arquitetura do Android pode ser subdividida em seis camadas (Bezerra, 2021):

- Aplicações: refere-se aos mais diversos aplicativos que possibilitam a interação do usuário, tais como: o navegador, a tela inicial, os contatos, dentre outros;
- *Framework* de aplicações: composto por bibliotecas escritas em C/C++, que são acionadas pelos programadores por meio de interfaces Java, dentre elas tem-se o gerenciamento de *Activitys* e *views*;
- *Runtime*: trata-se da camada responsável pela execução das aplicações;
- Bibliotecas Nativas: são relativas às biblioteca do C, *SQLite* (Banco de dados), *OpenGL* (Renderização 3D), etc.;
- O *Kernel* e ferramentas de baixo nível: necessários para ter acesso a recursos de *hardware*, como áudio, vídeo, e recursos de rede.

Na visão de Bezerra (2021), um dos principais ambientes de desenvolvimento para *Android* é o *Android Studio*. Trata-se de uma IDE que ajuda os desenvolvedores na concepção e programação de apps. Para o desenvolvimento da lógica da aplicação, as linguagens mais usadas são *Java* e *Kotlin*, enquanto a linguagem de marcação XML é adotada para as demarcações e conteúdo de *layout*.

Salienta-se que o acesso ao *Android* nativo é facilitado, visto que existem guias e tutoriais que podem ser seguidos, contribuindo para que a construção do aplicativo seja mais fácil e rápida. Isso sem considerar que a própria IDE faz inspeção do código a partir de verificações que mostram advertências (*warnings*) nos componentes que não estejam atendendo aos requisitos de acessibilidade (Bezerra, 2021). Por outro lado, os diferentes e variados formatos de telas dos dispositivos, acrescido dos diversos tipos de sistemas – iOS, *Android* e *Windows* – geram o desafio do desenvolvimento de interfaces para sites e aplicativos que sejam flexíveis, de modo que possam ser adaptadas a qualquer sistema, sem causar grandes transtornos para o usuário (Steffen, 2020).

2.2 Flutter

Pode-se afirmar que *Flutter* é um SDK de código aberto que foi criado pela *Google* com a finalidade de serem desenvolvidos aplicativos multiplataforma, o que significa ter capacidade de serem executadas diferentes sistemas operacionais. Sua linguagem base é o *Dart*, que geralmente é utilizado pela *Google* no desenvolvimento de aplicações para dispositivos móveis. Alessandria (2020) menciona que com o *Flutter* é possível desenvolver aplicações de forma rápida por meio da criação de interfaces amigáveis e acessíveis, além de ter acesso a um código nativo para as diferentes plataformas. Assim sendo, é possível a partir do *Flutter* desenvolver aplicações para *Android* e iOS, usando uma mesma base de código, uma vez que as diferenças entre os componentes de cada plataforma são abstraídas, sendo que a entrega dos ícones e comportamentos da interface são similares nos dois ambientes (Oliveira; Lima; Caridade, 2022).

Basicamente, o fluxo de desenvolvimento do *Flutter* é norteado pelos *Widgets*, que nada mais é do que componentes visuais para definir a interface que conterá botões, textos, e imagens em um aplicativo. Os *widgets* compõem uma árvore hierárquica na aplicação, em que cada um herda as propriedades do superior. Eles possuem um design específico tanto para a plataforma Android quanto para o iOS (Zammetti, 2020).

Araújo (2021) apresentou as seguintes características inerentes ao *Flutter* que podem ser vistas como vantagens importantes para quem tem a intenção de proceder com o desenvolvimento de aplicativos:

- Despensa conhecimentos prévios

Interfaces personalizadas são facilmente criados utilizando os recursos gráficos disponíveis como o motor gráfico *Skia*, que possui excelente desempenho e utiliza código-fonte aberto. A vantagem é que as atualizações de *software* não interferem nos *layouts* e *designs* personalizados em nenhum sistema operacional, pois ao contrário do que geralmente ocorre com outros *frameworks*, as chances de ocorrerem falhas são quase nulas.

- Redução de custos

A economia acontece pelo fato de ser dispensável o uso de diferentes plataformas e ferramentas de criação, implicando no menor custo de desenvolvimento de um aplicativo. Pelo fato de empregos serem gerados em decorrência do produto, todos os sistemas operacionais tendem a uma redução de gastos, devido à menor necessidade das ferramentas de desenvolvimento.

- Aumento de produtividade

Pela característica da estrutura cruzada, os desenvolvedores fazem uso da mesma base de código para ambos os sistemas sem a necessidade de produzir diferentes versões do aplicativo. A comunicação entre o aplicativo e a plataforma é facilitada pela compilação de código nativo do *Dart* e a falta de widgets OEM. O acesso mais rápido ao sistema, ou seja, o menor tempo de inicialização decorre do fato de as visualizações responsivas serem fornecidas sem a necessidade de *Javascript*. Os custos também são reduzidos devido à maior produtividade da equipe, que pode entregar mais em menos tempo.

2.3 *Sklearn*

Sklearn é um acrônimo de *Scikit-Learn*, que se refere a uma biblioteca de código aberto bastante conhecida por quem desenvolve aplicações em *Python* (Maciel *et al.*, 2024). Ela foi desenvolvida com a preocupação de dispor uma interface simples, porém eficiente, tornando-se popular devido, principalmente, à sua facilidade de uso e à sua integração perfeita com outras bibliotecas *Python*, como *NumPy*, *Pandas* e *Matplotlib* (Grus, 2016; Mcfarland, 2024). Conforme mencionado por Aware (2023), *Sklearn* é uma ferramenta bastante útil por oferecer uma grande quantidade de algoritmos de *machine learning* que podem ser utilizados para resolver problemas relacionados a várias ações como:

- Pré-processamento de dados: o *Sklearn* disponibiliza um número significativo de algoritmos para pré-processar dados, que é uma etapa necessária para deixar os dados em um formato adequado para serem usados pelos modelos de *machine learning*. Nesta etapa pode ser necessária realizar ações de escalonamento, normalização, tratamento de valores ausentes, e codificação de variáveis categóricas;
- Aprendizado supervisionado: A biblioteca contém algoritmos implementados a partir das principais técnicas de classificação, regressão e detecção de anomalias. O uso de tais algoritmos possibilita uma economia de tempo no treinamento de modelos de *machine learning* para prever ou categorizar a classe dos dados com base em exemplos previamente rotulados;
- Aprendizado não supervisionado: *Sklearn* também disponibiliza algoritmos prontos para serem usados em seu conjunto de dados cuja finalidade seja executar agrupamento das instâncias, redução de dimensionalidade dos atributos, ou até mesmo detecção de valores anômalos. Os algoritmos baseados em aprendizado não-supervisionado são úteis quando se deseja explorar e encontrar possíveis padrões em dados não rotulados;

- Avaliação de modelos: na biblioteca *Sklearn* é possível encontrar funções para avaliar o desempenho dos modelos de *machine learning*, sendo que tal desempenho pode ser mensurado por diferentes métricas, tais como: acurácia, precisão, *recall*, *F1-score*, e curvas ROC. Avaliar diferentes modelos permite selecionar o melhor para um dado problema específico;
- Seleção de atributos: há métodos no *Sklearn* que podem ser facilmente utilizados para selecionar, de forma automática, os melhores atributos de um conjunto de dados para induzir o modelo de machine learning. Quando executada essa ação, pode ocorrer uma melhora no desempenho preditivo em decorrência da redução da dimensionalidade dos dados;
- *Pipelines*: podem ser encontrados *pipelines* de pré-processamento e de modelagem, que geralmente são úteis para simplificar o fluxo de trabalho, além de aumentar as chances dos modelos de *machine learning* terem um desempenho satisfatório por estarem sendo aplicados de maneira consistente no contexto desejado;
- Integração com outras bibliotecas: uma outra vantagem do *Sklearn* está na facilidade de se integrar com outras bibliotecas de análise de dados e visualização, tornando-o uma opção bastante versátil quando se deseja executar projetos no âmbito da ciência de dados.

2.4 Python

Python é uma linguagem de programação interpretada por *script* e acessível, tendo como principais vantagens ser de código aberto, além da clareza e concisão em sua sintaxe, que torna mais legível o código-fonte, impulsionando a produtividade na construção de programas para automatizar as tarefas. Embora esta linguagem de programação tenha sido criada há mais de três décadas, em 1991, ela é ainda uma das mais utilizadas atualmente no mundo (Ferreira *et al.*, 2022).

Ao contrário de muitas linguagens de programação, em *Python* não é necessário escrever um comando para declarar variáveis, já que elas são automaticamente criadas quando se atribui um valor à variável desejada. Outro detalhe que não precisa se preocupar é a declaração dos tipos de variáveis, podendo, inclusive serem convertidas para outro tipo por meio de um *casting*. Os principais tipos de variáveis simples que podem ser usados no Python são do tipo: inteiro, real, *booleano* e *string* (Kalinowski *et al.*, 2023).

A linguagem *Python* tem se tornado bastante popular porque muitos usuários consideram uma ferramenta útil para a tarefa de limpeza, processamento, análise e visualização de dados em diversas áreas do conhecimento, como a área da saúde, devido ao fato de possuir uma ampla diversidade de bibliotecas e recursos. A disseminação da linguagem e o aumento no número de adeptos também decorre da existência de comunidades de usuários do Python, nas quais são compartilhados muitos recursos, como por exemplo, documentação, tutoriais e fóruns de suporte (Gaspar *et al.*, 2023).

Para Armesto *et al.* (2023), *Python* é bastante conhecido porque se baseia em um modelo de intuição que facilita alcançar aquilo que a comunidade científica considera sobre a importância de aproximar o conhecimento aplicado ao desenvolvimento de sistemas computacionais, de forma que haja uma interação intrínseca entre si. Nesse sentido, percebe-se que em determinados segmentos da sociedade, como no caso da saúde, existe a busca contínua pelo aprimoramento de saberes sistematizados, principalmente, de métodos que possam facilitar e potencializar os resultados de desempenho profissional (Chen; Liu., 2022). Em uma linha convergente, Silva *et al.* (2015) opinam que um modelo de aplicação voltada para o ensino-aprendizagem em saúde pode auxiliar profissionais já atuantes nesse mercado, proporcionando-lhes resultados importantes na otimização do uso de recursos, ferramentas, equipamentos e procedimentos. Desse modo, a tendência natural é que se tenham uma maior assertividade nos atendimentos, diagnósticos e tratamentos adequados conforme às necessidades e condições dos pacientes (Lobo, 2018). Por tudo isso, a linguagem de programação *Python* pode ser considerada útil quando aplicada a situações de áreas específicas, contribuindo em uma perspectiva científica mais promissora, significativa e robusta na busca pela efetividade do serviço, especialmente na área da saúde, que é primordial a minimização de erros por se tratar de vida humana (Armesto *et al.*, 2023).

2.5 Machine Learning

Machine learning, que traduzido ao português significa aprendizado de máquina, refere-se a uma subárea da inteligência artificial (Holmes; Bialik; Fadel, 2019; Nilsson, 2010). Embora no mundo atual, a expressão “Inteligência Artificial” esteja em moda, o conceito inerente a *machine learning* não é tão recente quanto se possa imaginar. Segundo Mackenzie (2015), as nuances de aprendizado de máquina, reconhecimento de padrões e modelagem estatística já eram, de certo modo, discutidos e pesquisados antes mesmo da Segunda Guerra Mundial em algumas áreas de aplicação da ciência como: administração pública e da indústria, além áreas comerciais como a avaliação do risco de crédito.

Mitchell (1997) define *Machine Learning* como qualquer programa de computador que melhora o seu desempenho, por meio da experiência, na execução da mesma tarefa que tenha sido executada anteriormente. Sabe-se que tradicionalmente um programa de computador deve executar passo a passos as instruções. No entanto, na era da Inteligência Artificial, os sistemas baseados em *machine learning* não demandam necessariamente que lhes sejam fornecidas todas as instruções de forma clássica (Domingos, 2015). As instruções são sensivelmente diferentes, pois “ao invés de algoritmos serem programados quanto ao que exatamente deverão fazer, de modo geral eles têm a habilidade de aprender o que fazer” (Holmes; Bialik; Fadel, 2010, p. 89). Os autores esclarecem que embora exista essa diferença, não significa que *machine learning* não requeira grandes esforços de programação. A verdade é que em vez de se serem desenvolvidos comandos diretos que levem aos resultados diretos, a programação em aprendizado de máquina faz uso de grandes volumes de dados nos algoritmos a fim de gerarem resultados preditivos em suas saídas.

Os sistemas baseados em *machine learning* são capazes de construir possíveis hipóteses a partir dos dados fornecidos em suas entradas, e durante o processo procuram fazer inferências “indutivas”. Para exemplificar, se um grande conjunto de dados contém vários exemplos de cisnes brancos, e nenhum de cisnes de outras cores, muito provavelmente o algoritmo irá fazer a inferência de que “todos os cisnes são brancos” (Nilsson, 2010). Este procedimento é uma inferência indutiva porque são hipóteses sujeitas a dados adicionais ou falseados.

Os sistemas de *machine learning* são executados a partir de grandes massas de dados – *big data*. Os dados são constituídos por instâncias descritas por um conjunto finito de características. Os algoritmos de *machine learning* fazem uso dos dados para identificar padrões e construir um modelo a ser usado para prever valores futuros. Holmes, Bialik e Fadel (2010) ilustram possíveis aplicações desses algoritmos, tais como a identificação de padrões históricos em: dados do mercado de ações e a previsão de movimentações futuras; conjunto de fotografias de pessoas nomeadas, prevendo quem é mostrado em outras fotografias; inúmeros padrões em sintomas relacionados à saúde para prever um diagnóstico específico. Knox, Williamson e Bayne (2019) afirmam que algoritmos são treinados para reconhecer vozes, rostos e imagens; fazer recomendações; dirigir carros de forma autônoma, entre outras finalidades.

Os algoritmos de *machine learning* também estão contidos em *softwares* de filtragem de SPAM nos serviços de *e-mail*; nos sistemas de recomendação de filmes, livros e outros produtos em sites de compra e plataformas de *streaming*; em robôs capazes de circular pelos andares de um hotel ou de uma fábrica; em dispositivos capazes de “conversar” com um ser humano (Holmes; Bialik; Fadel, 2019).

Existem duas principais paradigmas de aprendizado de máquina: o aprendizado supervisionado e o aprendizado não supervisionado, que são destinados para as tarefas de predição e descrição, respectivamente. Todavia, há tarefas que não se encaixam nessa hierarquia citada, como o aprendizado semissupervisionado, aprendizado ativo e aprendizado por reforço (Faceli *et al.*, 2021). A seguir serão explanadas as diferenças entre o processo de aprendizado supervisionado e o processo de aprendizado não-supervisionado.

2.5.1 APRENDIZADO SUPERVISIONADO

Em aprendizado supervisionado deve ser fornecido ao sistema um conjunto que tenham uma quantidade significativa de dados descritos por atributos de entrada e atributo de saída. O atributo de saída deve conter o valor conhecido para cada instância, ou seja, os dados já devem ter sido previamente classificados para a construção do modelo preditivo. Assim sendo, durante o processamento de treinamento do sistema, tenta-se encontrar uma função que relacione, da melhor forma possível, os dados com rótulos da classe. Essa é a abordagem usada para identificar pessoas em fotografias que os usuários associam aos seus perfis nas redes sociais (a máquina usa milhões de fotos submetidas pelos usuários e rotuladas por eles mesmos para identificar e rotular automaticamente essas mesmas pessoas (Holmes; Bialik; Fadel, 2019).

Modelos concebidos a partir de um paradigma de aprendizado supervisionado são treinados a partir de um conjunto de instâncias descritas pelos valores de seus atributos de entrada e do valor do atributo-alvo. Neste caso, o modelo é treinado para identificar uma função que faça o mapeamento entre os valores dos atributos preditivos (valores de entrada) e o valor do atributo-alvo (valor de saída). Após treinado, o modelo está pronto para predizer o valor de saída dos exemplos descritos apenas pelos atributos de entrada. Se o valor de saída é simbólico, trata-se de um problema de classificação e se o valor de saída é um número então podemos estar diante de um problema de regressão (Faceli *et al.*, 2021).

A capacidade preditiva de um modelo classificador pode ser avaliada por meio da acurácia, que é determinada pela taxa de instâncias para as quais o valor da classe é predito corretamente. O cálculo da Área sob a Curva ROC também resulta em uma medida comumente usada para mensurar o desempenho de um sistema preditivo (Tan; Steinbach; Kumar, 2006). Para calcular o desempenho de modelos de regressão, as principais métricas são: o erro quadrático médio e a distância absoluta média. Essas medidas comparam o valor predito pelo modelo para cada instância com o respectivo valor verdadeiro, de modo que quanto menor é o valor calculado para essas medidas melhor é a capacidade preditiva do modelo (Faceli *et al.*, 2021).

2.5.2 APRENDIZADO NÃO SUPERVISIONADO

Considerando o contexto e situações deste trabalho de conclusão de curso, procedeu-se com o aprendizado não supervisionado. De acordo com Kalinowski *et al.* (2023), no aprendizado não supervisionado, o conjunto de dados fornecido ao sistema não possui o valor da classe, ou seja, as instâncias não são previamente rotuladas. Por essa razão, durante o treinamento, o sistema de *machine learning* tenta encontrar, por meio da exploração dos dados padrões não-triviais em tais dados, agrupando-os por meio de alguma medida de similaridade ou dissimilaridade entre os objetos. Dentre as medidas de similaridade mais comuns está a correlação, enquanto a distância euclidiana é uma das mais conhecidas medidas de dissimilaridade desde que os objetos sejam descritos por atributos numéricos (Faceli *et al.*, 2021).

Para Sicsu, Samartini e Barth (2023), o aprendizado não supervisionado caracteriza-se por algoritmos que não fazem uso de uma variável alvo que consiga direcionar os resultados, sendo que o objetivo é encontrar o melhor agrupamento de dados possível. O agrupamento (*clustering*) é muito utilizado em análise exploratória de massas de dados com o objetivo de encontrar padrões ou agrupamentos em dados (Silva *et al.*, 2018). É muito útil em casos que o esforço para a classificação dos dados não compense ou caso não haja dados suficientes para rotular as saídas desejadas.

A principal característica dos modelos descritivos criados a partir do paradigma de aprendizado não-supervisionado é o não conhecimento do valor da classe dos exemplos utilizados para treinar o modelo. Neste caso, o sistema de machine learning usa medidas de proximidades para identificar grupos de instâncias, de modo que instâncias do mesmo grupo estão mais próximas entre si quando comparadas com instâncias de grupos diferentes (Tan; Steinbach; Kumar, 2006).

Para avaliar a qualidade de um agrupamento gerado podem ser usados critérios relativos que comparem os agrupamentos, utilizando algum aspecto inerente aos dados. Dentre os principais critérios, destacam-se as medidas de validação interna e as medidas de validação externa (Faceli *et al.*, 2021).. Em validação interna, as medidas usam somente os dados originais para mensurar a qualidade do agrupamento, como exemplo o índice de Dunn e a silhueta média. Os critérios externos precisam de uma estrutura definida previamente para proceder a avaliação do agrupamento, comparando a solução obtida com a teoricamente esperada, como o índice de Rand (Sicsu; Samartini; Barth, 2023).

2.5.3 TIPOS DE ATRIBUTOS

Independentemente do tipo de abordagem de aprendizado a ser adotado, é importante que o conjunto de dados para induzir o modelo de *machine learning* seja constituído por uma quantidade significativa de instâncias descritas por um conjunto de atributos. O Quadro 1 mostra os possíveis tipos atributos e suas principais características (Faceli *et al.*, 2021).

Quadro 1 – Tipos de atributos.

Tipos de atributos		Características	Exemplos
Categórico (Qualitativo)	Nominal	Os valores são apenas nomes (símbolos) diferentes; Não há uma ordem entre seus valores; Uso de operadores de comparação ($=$ e $\neq$).	Número de documento; Número do CEP; Cores;
	Ordinal	Indica uma ordem dos valores representados; Uso de operadores ($=$, $\neq$, $<$, $>$, $\leq$, e $\geq$).	Número de endereço; Hierarquia militar.
Numérico (Quantitativo)	Intervalar	Representa números que variam em um intervalo; Não faz sentido usar operadores que multiplicam e dividem.	Temperatura em Celsius; Datas.
	Racional	Faz sentido usar operadores que multiplicam e dividem; Há um zero absoluto com uma unidade de medida.	Quantidade monetária; Distância.

Fonte: Adaptado de Faceli *et al.* (2021)

Uma descrição mais detalhada do uso da inteligência artificial (IA) na área da saúde é apresentada na próxima seção.

2.6 IA na Saúde

A relação da saúde com a tecnologia ocorre por meio da disrupção de práticas tradicionais. Kaufman (2022) afirma que fatores como tecnologias digitais, aplicativos, dispositivos móveis, IA, telemedicina, blockchain, entre outros, estão transformando o acesso a serviços de saúde, a relação médico-paciente, o cuidado do paciente com sua saúde além de impactar os setores periféricos ligados a saúde.

Ao investigar o uso da IA no contexto da saúde, os resultados encontrados por Nascimento Neto *et al.* (2020) mostraram que sua aplicação pode auxiliar vários segmentos de saúde em relação ao armazenamento e recuperação de dados. Os autores apontam que os benefícios devem ser vistos como um mecanismo de apoio ao trabalho e nunca como uma substituição do trabalho humano. Destacam ainda que essa relação deve ser conduzida com extremo cuidado em razão das questões éticas e de humanização que podem ser feridas.

Em opinião convergente, Nogueira (2022) ressalta que a utilização da IA não ocorre como uma substituição do profissional de saúde, mas sim como uma maneira de melhorar o processamento e o entendimento dos dados e dos padrões disponíveis, possibilitando a extração de informações e auxílio nos processos.

Gerar informações confiáveis a partir de dados em saúde é muito relevante para o processo de tomada de decisões, principalmente quando se deseja proporcionar uma melhor qualidade no acompanhamento e tratamento de um paciente. Os dados podem ser compostos por informações históricas de pacientes, para os quais se conhecem os tratamentos realizados, os resultados clínicos, os custos de saúde e outros aspectos relacionados a este contexto. A partir da adoções dos registros eletrônicos de saúde, sensores e dispositivos médicos, a quantidade de dados disponíveis nesta área só tem aumentado (Brasil, 2020).

Petrovskiy (2003) defende que não adianta ter apenas acesso a um grande volume de dados sobre a saúde, é imprescindível capacitar os profissionais da área com a finalidade de coletar, gerenciar e analisar esses dados de maneira apropriada, uma vez que a interpretação dos dados requer conhecimento tanto em análise de dados quanto em saúde, a fim de evitar inferências incorretas e garantir tomadas de decisão eficazes. As bases de dados em saúde envolvem diversos tipos de dados e armazenam grandes quantidades de informação. Com o desenvolvimento das tecnologias da informação que impulsiona o crescimento das bases de dados, em dimensão e em complexidade, surgem novas necessidades de análise de grande quantidade de dados (Petrovskiy, 2003).

Dentre os serviços de saúde, pode-se imaginar que a área hospitalar é um dos mais relevantes por causa da existência dos vários procedimentos de maior complexidade e custo, o que tem indicado que as bases de dados sobre as hospitalizações sejam o principal foco das mais diversas análises (Shortliffe; Cimino, 2006). Realizar uma análise de dados relativos à área da saúde pode ajudar a identificar padrões, prever resultados e melhorar a qualidade e a eficiência dos serviços de saúde. Entretanto, deve-se ter um mínimo de garantia de que tais dados sejam verdadeiros, confiáveis, seguros e atualizados. Salienta-se que é extremamente importante garantir a proteção dos dados pessoais dos pacientes, que dentre outras ações que devem ser providas está o armazenamento seguro dos dados em conformidade com as leis e regulamentações vigentes (WHO, 2020).

2.7 Gravidez e a Importância do Pré-Natal

Para qualquer mulher, a gravidez representa um acontecimento ímpar em sua vida, podendo ser marcada por mudanças fisiológicas e psicológicas, além do impacto em seu cotidiano e qualidade de vida pessoal, social e familiar (Pereira, 2013). Para muitas, é uma época em que são experimentadas fortes emoções, emergindo medos, fragilidades e questionamentos relacionados às alterações funcionais do seu corpo e da sua nova realidade materna (Mira *et al.* 2021).

As transformações ocorrem por causa da necessidade de buscar entender como se dará a relação da grávida com o ser que está em seu ventre, além dos desconfortos inerentes ao período da gestação (Silva *et al.*, 2016). Os desconfortos não são necessariamente iguais para todas as mulheres, mas geralmente ocorrem efeitos como: náuseas, vômitos, pirose, cefaleias, lombalgias, fadiga, varizes nos membros inferiores, e distúrbios do sono (Nené; Marques; Batista, 2020).

Do ponto de vista obstétrico, é possível que uma mulher grávida sinta conforto, ainda que durante a gravidez tenha que enfrentar desconfortos (Charles; Yount; Morgan, 2013). Para isso, é importante que as grávidas tenham um acompanhamento Pré-Natal adequado, sendo realizado por profissionais especialistas em Saúde Materna e Obstetrícia e/ou generalista.

É necessário, primeiramente, conhecer o conceito de exame pré-natal para então compreender a importância de executá-lo. A Agência Nacional de Saúde Suplementar (Brasil, 2024a) define o Pré-Natal como sendo uma consulta médica em que a mulher gestante deve ser atendida por um profissional habilitado pelo Conselho Regional de Medicina, com a finalidade de receber orientação terapêutica, controle e acompanhamento clínico da gravidez. Sendo assim, consideram-se que as consultas de pré-natal devam ser realizadas por ginecologistas, obstetras, médico generalista, médico clínico, e/ou médico de família. Esses profissionais devem abordar os temas suscetíveis à gravidez para que a paciente se sinta acolhida e segura (Silva *et al.*, 2016).

Além das consultas, no período pré-natal a mulher deve realizar uma série de exames direcionados para prevenções, diagnósticos e tratamentos de doenças e anomalias, que ajudam não somente a mulher grávida, mas toda a família envolvida. Isso sem considerar que os profissionais que fazem o acompanhamento da gravidez concedem apoio com fornecimento de orientações, dicas e auxílio psicológico. Nas consultas de pré-natal devem ser prescritas ações que visem o conforto gestacional materno-fetal, reduzindo as ansiedades que muitas vezes estão atreladas aos desconfortos físicos, emocionais e psicológicos (Martins *et al.*, 2020).

Conforme o Ministério da Saúde (Brasil, 2016), existem várias vantagens associadas a frequência constante nos exames pré-natais, dentre as quais se destacam: a identificação de doenças já presentes no organismo da gestante que estavam evoluindo de forma silenciosa; a detecção de problemas com o feto, como a má formação; avaliação da placenta que possibilita direcionar os tratamentos adequados; identificação precoce da pré-eclâmpsia, dentre outros benefícios. A realização dos exames da maneira correta também é fundamental para garantir uma gestação saudável e sem intercorrências, fato justificado por Bezerra (2023) ao demonstrar que o início tardio do pré-natal aumenta a possibilidade de resultados adversos.

De acordo com a Organização Mundial da Saúde, há cerca de cinco anos atrás, morriam diariamente, em média, 810 mulheres em todo o mundo decorrente das complicações relacionadas ao parto e à gravidez, sendo que a grande maioria (94%) dessas mortes tem sido registradas em países pouco desenvolvido, principalmente, aqueles caracterizados pela renda baixa e média-baixa (WHO, 2019). Agrawal (2015) já afirmava que as principais causas de mortes de mulheres grávidas eram causadas pelas complicações obstétricas, como pré-eclâmpsia, trabalho de parto prolongado e similares. Outras situações que podem colocar em risco a vida da grávida e de seu filho são as complicações maternas graves causadas por circunstâncias desfavoráveis do parto, como perda severa de sangue, falha no progresso do trabalho de parto, apresentação anormal do feto, parto prematuro, dentre outras situações (Pallasmaa; Ekblad; Gissler, 2008). Todavia, acredita-se que a maioria dessas complicações pode ser evitadas se forem adotadas medidas apropriadas que garantem um procedimento de parto com riscos minimizados. Por exemplo, em caso de posição e apresentação anormais do feto, cesariana ou parto com fórceps pode ser o procedimento de parto mais seguro (Shearer, 1993; Patel; Murphy, 2004).

A verdade é que o avanço contínuo e recente da tecnologia tem contribuído para reduzir a taxa de mortes maternas (WHO, 2024). No entanto, mesmo com essa nova realidade, ainda pode ser considerada uma luta desafiadora a garantia da segurança da mãe e da criança durante a gravidez. Nesse contexto, é possível adotar medidas para que os riscos relacionados à gravidez sejam reduzidos, desde que as complicações forem prevenidas com antecedência e as medidas preventivas forem adotadas em tempo hábil. Para contribuir com esta prevenção, o uso da modelagem preditiva torna-se emergente e necessária para salvar a vida das mães e de seus bebês.

2.8 Gravidez e o uso de Machine Learning

Considerando a enorme amplitude de aplicações da Inteligência Artificial para a sociedade, mesmo restringindo o seu escopo para abranger somente as gestantes, ainda assim é possível inúmeros trabalhos que buscam alcançar diferentes objetivos com uso dessa tecnologia. Quixabeira *et al.* (2024) investigaram trabalhos que aplicam *Machine Learning* para predição de doenças e complicações que ocorrem durante a gravidez, encontrando modelos computacionais que apresentaram eficácia em sua execução demonstrando o impacto positivo que a aplicação da Inteligência Artificial nesse ramo pode trazer. Os principais resultados que os autores encontram estão sintetizados no Quadro 2.

Quadro 2 – Principais trabalhos de *machine learning* aplicado em gravidez.

ID	Autoria	Objetivo	Modelos de IA utilizados	Principais resultados
1	Jhee <i>et al.</i> (2019)	Desenvolver modelos de aprendizado de máquina para prever pré-eclâmpsia de início tardio usando dados de prontuários eletrônicos hospitalares.	Regressão logística, árvores de decisão, Naive Bayes, SVM, Random Forest e Descida gradiente estocástica	Combinação de fatores maternos e dados laboratoriais pré-natais comuns do início do segundo trimestre até o início do terceiro trimestre previu com eficácia a pré-eclâmpsia de início tardio.
2	Rittenhouse <i>et al.</i> (2019)	Utilizar algoritmos de IA para identificação de recém-nascidos prematuros	Regressão logística binária, Random-Forest e generalized additive model.	Modelo com variáveis: DUM, peso ao nascer, parto de gêmeos, altura materna, hipertensão no trabalho de parto e status HIV teve acurácia acima de 94%.
3	Khatibi <i>et al.</i> (2019)	Propor métodos para previsão de nascimento prematuro e partos prematuros espontâneos.	árvores de decisão, Support Vector Machine e Random-Forest.	Os resultados experimentais tiveram acurácia de 81% na predição de nascimento prematuro.
4	Gao <i>et al.</i> (2019)	Identificar morbidade materna grave a partir de registros eletrônicos de saúde.	Regressão logística	Novos indicadores de morbidade materna grave: distúrbios de fluidos, síndrome de resposta inflamatória sistêmica e acidose.
5	Sun <i>et al.</i> (2019)	Investigar se as características da textura intraplacentária da ressonância magnética placentária de rotina podem prever a placentação invasiva	Generalized additive model.	O modelo previu com precisão a invasão placentária, que facilita a tomada de decisão clínica para mulheres grávidas com suspeita de invasão placentária
6	Malacova <i>et al.</i> (2020)	Quantificar e validar a precisão preditiva de um conjunto de fatores de risco coletados rotineiramente para prever natimortos.	Redes neurais artificiais	O classificador previu 45% de natimortos para todas as mães e 45% de natimortos após a inclusão do histórico de gravidez anterior.
7	Guo <i>et al.</i> (2020)	Analisar a precisão preditiva de complicações na gestação a partir do perfil do promotor. do genoma completo do DNA plasmático.	Regressão logística	Previsão das complicações na gravidez com precisão de 80% para macrosomia, 79% para crescimento fetal, e 83% pré-eclâmpsia.
8	Artzi <i>et al.</i> (2020)	Analisar a precisão preditiva de diabetes mellitus gestacional com base em registros eletrônicos de saúde.	Gradient Boosting Machines	Predição de diabetes mellitus gestacional com alta precisão mesmo no início da gravidez (auROC) = 0,85).
9	Li <i>et al.</i> (2021)	Prever o risco de pré-eclâmpsia em mulheres usando algoritmos de IA, com base em registros eletrônicos de saúde coletados no início do segundo trimestre.	regressão logística, Support Vector Machine, Random Forest reforço de gradiente extremo (XGBoost).	A característica mais preditiva do desenvolvimento de pré-eclâmpsia foi a glicemia plasmática em jejum, seguida pela pressão arterial média e índice de massa corporal.
10	Liu <i>et al.</i> (2022)	Utilizar métodos de IA para analisar dados clínicos e laboratoriais obtidos durante a triagem pré-natal no início da gravidez.	Rede neural profunda, regressão logística, árvore de decisão, SVM e Random Forest.	Identificação automática de características preditivas alto desempenho preditivo sobre o risco de pré-eclâmpsia usando informações do início da gravidez
11	Zhang <i>et al.</i> (2023)	Desenvolver um nomograma baseado em múltiplos fatores de risco comuns de registros médicos eletrônicos de saúde.	Regressão logística multivariada.	O estudo desenvolveu um nomograma simples de usar para prever diabetes mellitus no início da gravidez.
12	Watanabe <i>et al.</i> (2023)	Analisar a previsão de diabetes mellitus gestacional usando a IA a partir de registros médicos.	Árvores de decisão, Support Vector Machine e Random-Forest.	Alta precisão e interpretabilidade para prever o diabetes mellitus gestacional usando dados de coorte de nascimentos.
13	Cersonsky <i>et al.</i> (2023)	Criar e refinar modelos de IA para prever natimortos usando dados disponíveis antes da viabilidade (22-24 semanas).	Random-Forest	Uma aplicação que usou variáveis clínicas identificou com 85% de precisão as gestações que resultariam em natimortos.

Fonte: Quixabeira et al. (2024).

Além dessa coletânea de trabalhos publicados, também é importante destacar a abordagem de Abouelyazid e Xiang (2021), que buscaram verificar o estado de saúde dos fetos por meio dos dados de cardiogramas, tendo obtidos resultados promissores com o classificador criado a partir da Árvore de Decisão. Embora ainda não tenha atingido um nível suficiente para uso prático, foi demonstrado o potencial de aplicação do modelo como ferramenta de auxílio na verificação da saúde fetal.


Dentro do contexto do presente trabalho, um aspecto muito importante que deve ser analisado é o reconhecimento do perfil da gestante. Ainda que não tenham sido aplicada nenhuma técnica de aprendizado de máquina, Maia, Marrone e Martins (2021) entrevistaram, em um determinado centro de saúde, gestantes para a obtenção de informações sociodemográficas. Em sua pesquisa, eles conseguiram extrair dados relevantes em relação à localização, tempo de deslocamento e poder econômico, que podem ser levados em consideração ao decidir quais atributos relevantes devem estar contidos na coleta de dados, que posteriormente, serão usados em um sistema de *Machine Learning*.

3 METODOLOGIA

Em geral, e conforme afirmam Amorim *et al.* (2023, p. 379), “as atividades do ciclo de vida de aprendizado de máquina são de natureza exploratória, iterativa e requerem muita experimentação”. Ao longo do ciclo, são necessárias realizar várias etapas inerentes aos procedimentos que envolvem desde a escolha do conjunto de dados para ser submetido ao modelo de machine learning até a avaliação da capacidade de generalização do modelo. Uma dessas etapas deve ser dedicada à manipulação dos dados para que estejam adequados para o uso do modelo de *machine learning* (Amorim *et al.*, 2023).

Considerando um modelo classificador baseado na abordagem de treinamento supervisionado, Amershi *et al.* (2019) propuseram o ciclo de vida de aprendizado de máquina que está ilustrado na Figura 1. A primeira etapa consiste em identificar quais modelos são os mais adequados para o problema dado. Em seguida, procede-se com a coleta de dados visando o treinamento do modelo. Mas, antes é necessário realizar a limpeza de dados ruidosos e/ou inconsistentes. Caso os dados ainda não estejam com a sua classe rotulada, recomenda-se procurar um especialista para providenciar a rotulação. A etapa de engenharia de recursos envolve a escolha dos parâmetros do algoritmo que possa prover o melhor resultado, e isso está diretamente atrelada à fase do treinamento do modelo. A avaliação do modelo pode ser feita usando conjunto de testes para mensurar a sua capacidade preditiva. E, uma vez que o modelo tenha tido uma avaliação satisfatória, poderá ser implantado e monitorado continuamente.

Figura 1 – Etapas do ciclo de vida de *machine learning*.



Fonte: Amershi *et al.* (2019).

Para este presente trabalho, a metodologia adotada foi baseada na proposta feita por Amershi *et al.* (2019), sendo que foram realizadas algumas adaptações, de modo que o ciclo de desenvolvimento do sistema de machine learning proposto foi constituído das 8 (oito) etapas ilustradas na Figura 2.

Figura 2 – Metodologia



Fonte: Adaptado de Amershi *et al.* (2019).

3.1 Delimitação do Tema

Na etapa inicial do trabalho foram definidos o tema explorado e a sua delimitação. Também foram estabelecidos os objetivos geral e os específicos como forma de dar um norteamento à pesquisa desenvolvida. Em seguida, houve um trabalho de levantamento bibliográfico para compor o referencial teórico e permitir a criação da metodologia.

As fontes bibliográficas desta pesquisa foram artigos científicos obtidos através do *Google Scholar*, no qual os termos utilizados nos motores de pesquisa foram as seguintes: “Aprendizado de máquina”, “*Machine learning*”, “Inteligência artificial”, “*Artificial Intelligence*”, “Gravidez”, “*Pregnancy*”, “*Android*”, “*Flutter*”, “Aprendizado não-supervisionado”, “*Unsupervised learning*”, “*Python*”, “*Scikit-learn*”, e “Pré-natal”, com alguns conjuntos sendo formados para pesquisas mais específicas. Além disso, foram consultados livros específicos para embasar as técnicas que foram utilizados para a implementação dos algoritmos previstos no projeto.

3.2 Escolha do *Dataset*

Com a definição do problema e considerando a proposta da criação de um modelo de aprendizagem de máquina, a composição do conjunto de dados é uma etapa fundamental para o desenvolvimento do projeto e garantia da qualidade do sistema desenvolvido.

A ideia inicial era utilizar uma base de dados existente do Sistema Único de Saúde (SUS) que possuem dados completos sobre as gestantes. No entanto, devido ao fato de os dados serem considerados sensíveis, os mesmos estão disponíveis de forma criptografada, tornando-os inacessíveis. Desse modo, houve a necessidade de buscar outros métodos para a constituição do *dataset*.

Diante da situação exposta, a forma escolhida para realizar a coleta de dados foi por meio de um aplicativo para dispositivos móveis com o propósito de auxiliar as gestantes a fazerem o acompanhamento durante o processo de sua gestação, com informações básicas da gravidez, lembretes sobre os exames e outras funcionalidades. Ao criar um cadastro para utilizar o aplicativo, seriam coletados alguns dados sociodemográficos e, a partir disso, uma base de dados real com informações das gestantes seria formada. Uma vez que não haveria uma maneira de especificar se as mães iriam abandonar ou não os exames pré-natal devido a limitação do tempo para a coleta dos dados, não seria possível trabalhar com dados rotulados, o que justifica a abordagem não supervisionada adotada durante o projeto.

3.3 Tratamento do *Dataset*

As ações desenvolvidas nesta fase foram fundamentais para garantir a eficiência do modelo de aprendizagem de máquina, uma vez que dados não tratados poderiam provocar flutuações e perturbações no desempenho do algoritmo. Para esse processo foram utilizadas técnicas de normalização do banco de dados, tratamento de dados ruidosos, verificação de importância dos atributos, entre outros recursos.

Tal tratamento foi realizado utilizando o *Python* com a biblioteca *Pandas*, que trabalha com manipulação e análise de dados, e *Scikit-Learn*, que aborda métodos de aprendizado de máquina. Nela existem diversas técnicas que podem ser utilizadas para preparar o *dataset* de modo a otimizar o processamento, diminuir o consumo de recursos e melhorar a performance posterior do modelo (Gupta; Bagchi, 2024).

3.4 Escolha do Algoritmo

A etapa de escolha do algoritmo foi caracterizada, inicialmente, pelo entendimento das necessidades do problema investigado. Uma vez entendido os pontos-chaves foi possível escolher os algoritmos que pudessem ter melhor desempenho dadas as características do problema. Assim, foi testada a compatibilidade do problema com os algoritmos, visando escolher aqueles com maior probabilidade de performar.

Como explicado anteriormente, devido à natureza dos dados coletados, a abordagem utilizada foi o paradigma não-supervisionado. Existem diversas técnicas como o *clustering*, *biclustering* e modelos de rede neural que trabalham com esse paradigma. Assim, foram analisadas as funcionalidades, os pontos fortes e os pontos fracos de cada algoritmo a fim de determinar qual com o melhor funcionamento para o objetivo do projeto.

3.5 Treinamento do Modelo

Nesta fase, ocorreu a aplicação dos algoritmos obtidos na fase anterior no *dataset*. Houve a confirmação da eficácia do modelo de *machine learning* em relação ao problema e da capacidade de visualização de subajuste do modelo.

O treinamento do modelo ocorreu por meio de algoritmo implementado no *Python*, fazendo uso da biblioteca *Scikit-Learn* que é uma das bibliotecas do *Python* mais utilizadas para trabalhar com aprendizado de máquina. Essa biblioteca possui diversos métodos já implementados com vários algoritmos para apenas personalizar e ajustar os parâmetros, além de haver uma documentação bem especificada e com muitos trabalhos de exemplos que podem ser consultados para um melhor entendimento.

Também foram utilizadas as bibliotecas *MiniSom*, capaz de trabalhar com redes neurais do tipo SOMs, e *TensorFlow*, com classes e funções para a construção de redes neurais por camadas. Ambos implementados na tentativa de aumentar a eficácia dos modelos de agrupamento ao trabalharem com os dados de entrada.

3.6 Teste do Modelo

Para testar os modelos de aprendizado de máquina foi utilizado a técnica *Principal Component Analysis* (PCA), cuja implementação ocorreu por meio do uso novamente do *Scikit-Learn*, para realizar a redução da dimensionalidade dos dados que passaram pelos modelos treinados transformando-os em dados bidimensionais, capazes de serem utilizados para a representação visual. As figuras obtidas demonstram os diferentes agrupamentos formados pelos algoritmos treinados e utilizados.

3.7 Aperfeiçoamento do Modelo

Após a fase anterior, os modelos foram pontuados de acordo com a *SilhouetteScore*, para verificar a separação e coesão dos grupos formados, aqueles com os melhores desempenhos foram escolhidos para refinar o trabalho, sendo que para isso foi aplicado o procedimento denominado "*fine timing*", que consiste em colocar os melhores valores nos hiperparâmetros para que o modelo final tenha um resultado capaz de auxiliar os profissionais de saúde e cumprir com o objetivo desse projeto.

3.8 Avaliação do Modelo

Para a avaliação do modelo foram utilizadas diversas métricas de validação interna disponibilizadas pelo *Scikit-learn*. Os principais resultados encontrados durante os experimentos computacionais estão expostos no próximo capítulo através de gráficos que foram construídos a partir dos recursos disponibilizados na biblioteca *matplotlib*.

4 RESULTADOS

4.1 Delimitação do Tema

Durante a delimitação do tema, após a ideia ser definida, ocorreu um processo de pesquisa nas referências bibliográficas para compor os conhecimentos básicos que foram utilizados para embasar o projeto proposto e sua aplicação. A partir dos termos fornecidos nos motores de pesquisa, os achados mais importantes foram:

- Dificuldades na gravidez e importância do pré-natal;
- Relação da inteligência artificial com saúde e gravidez;
- Histórico e importância dos dispositivos e aplicativos *Android*;
- Importância, vantagens e aplicação do Flutter;
- Funcionalidades, importância e características do aprendizado de máquina;
- Aplicações, vantagens, desvantagens e técnicas de aprendizado não-supervisionado;
- Utilização do *Python* e suas bibliotecas como *Scikit-learn*, *Pandas*, *Seaborn* e *Tensorflow*.

Tendo o entendimento teórico bem fundamentado, partiu-se para o desenvolvimento prático do projeto, iniciando com a escolha do *dataset*, que está detalhada na próxima seção.

4.2 Escolha do *Dataset*

A etapa de escolha do *dataset* teve algumas complicações, visto que a proposição inicial era a utilização de um *dataset* desenvolvido pelo Sistema Único de Saúde (SUS) que já continha todas as informações e dados relevantes relacionados às gestantes. Contudo, como se trata de dados sensíveis e confidenciais, eles são criptografados e não acessíveis a qualquer pessoa.

Embora fosse possível buscar algum conjunto de dados disponível *online*, isso não foi efetivado porque as características locais podem afetar os diferentes perfis que serão formados. Assim sendo, a alternativa encontrada foi a criação de um *dataset* próprio contendo as características desejadas. Após serem discutidas as possibilidades, o desenvolvimento de um aplicativo para dispositivos móveis que pudesse, não apenas realizar essa coleta, mas também auxiliar as gestantes durante a gravidez foi a abordagem escolhida.


O aplicativo foi desenvolvido utilizando o *Flutter*, que é uma estrutura de código aberto da *Google* capaz de permitir o desenvolvimento de uma aplicação multiplataforma por meio de uma única base de código. A vantagem de sua utilização está no aumento da produtividade e na facilidade de futuramente implementar uma versão para dispositivos iOS. A arquitetura utilizada foi o *Model-View-ViewModel* (MVVM), que é baseado nos três elementos que formam o nome. De maneira geral, o *Model* trata-se da camada de negócios da aplicação, a *View*

apresenta a interface do usuário e a *ViewModel* realiza a integração entre os dois elementos anteriores, coordenando operações e invocando outras na *Model*.

Foram implementados alguns pacotes para auxiliar no desenvolvimento do aplicativo, com diversas finalidades, tais como auxiliar no controle de rotas, páginas e módulos (*flutter_getit*), gerenciamento de estado (*signals_flutter*), gerenciamento de requisições HTTP (*dio*), validação e formato de formulários (*validatorless*, *brasil_fields*) e armazenamento local de dados (*sqflite*, *drift*, *drift_sqflite*).

Para acessar o aplicativo, a usuária deve entrar no sistema, informando seu e-mail e senha (Figura 3). Caso ainda não tenha uma conta cadastrada, é necessário criar uma para então ter acesso as funcionalidades do aplicativo. Em caso de esquecimento da senha, a tela inicial também disponibiliza uma forma de recuperá-la.

Figura 3 – Tela do *login*.

A imagem mostra a tela de login de um aplicativo. O fundo é uma cor sólida de roxo claro. No centro, há um formulário branco com cantos arredondados. No topo do formulário, o título "Login" está em uma fonte preta, negrito. Abaixo do título, há dois campos de entrada de texto com bordas arredondadas e um fundo de roxo muito claro. O primeiro campo é rotulado "E-mail" e o segundo "Senha". À direita do campo "Senha", há um ícone de olho dentro de um círculo, usado para alternar a visibilidade da senha. Abaixo dos campos, há um link de texto "Esqueceu sua senha? Clique aqui!". Abaixo do link, há um botão de login com o texto "ENTRAR" em letras maiúsculas brancas sobre um fundo de roxo escuro. No rodapé do formulário, há outro link de texto "Não possui conta? Clique aqui!".

Fonte: Autoria Própria (2024).

Em relação as funcionalidades do aplicativo, elas estão divididas em sete módulos: perfil; consultas e exames; vacinas; medicamentos; informações básicas; gestação e parto, conforme pode ser observado na Figura 4. As informações são salvas localmente em um banco de dados *Structured Query Language* (SQL) e possui a capacidade de interagir com outros programas, serviços ou *Application Programming Interface* (API) através de requisições HTTP.


Figura 4 – Tela principal.



Fonte: Autoria Própria (2024).

Durante a gestação é importante que a mulher esteja com boa saúde e protegida contra possíveis enfermidades. Para tanto, deve-se realizar consultas e exames periódicos, bem como tomar as vacinas recomendáveis. Um controle sobre as informações de consultas, exames e doses das vacinas, conforme mostrado na Figura 5, pode ser feito por meio das primeiras opções mostradas no *Home* do aplicativo, mais especificamente usando as funcionalidades “Consulta e Exames” (Figura 5a) e “Minhas Vacinas” (Figura 5b).

Figura 5 – Telas de controle de consultas, exames e vacinas.



Fonte: Autoria Própria (2024).

Dentre as funcionalidades que aparecem na parte inferior da tela “*Home*”, tem-se a funcionalidades “*Gestação*” e “*Parto*”, que estão exemplificadas na Figura 6. Ao clicar na opção “*Gestação*”, a gestante pode cadastrar informações relativas à sua gravidez, tais como: nome do profissional que a acompanha no período pré-natal, datas de consultas pré-natal e data do parto (Figura 6a.). Ter um plano de parto bem definido pode contribuir para o bem-estar da mãe e do bebê. As principais informações resumidas sobre o plano de parto podem ser visualizadas rapidamente na tela do aplicativo (Figura 6b). A corretude dos dados é fundamental para o processo de treinamento do modelo de aprendizado de máquina, e elevar a capacidade de gerar informações precisas sobre classificação ou agrupamento dos dados.

Figura 6 – Tela de gestação e plano de parto.

a. Tela de gestação

b. Tela de plano de parto

Fonte: Autoria Própria (2024).

Dentro da funcionalidade ‘Parto’ é possível acessar outras informações como as que estão mostradas na Figura 7. As informações detalhadas do plano de parto (Figura 7a) podem ser visualizadas e editadas a qualquer momento. Para muitas mulheres o parto pode ser um momento de grande apreensão e ansiedade, principalmente para as mães que irão dar luz ao seu primeiro filho, por isso, é recomendável que ela indique antecipadamente os seus desejos que gostaria que ocorressem no momento do parto. Para mostrar suas escolhas, basta assinalar a resposta para cada uma das perguntas contidas na tela (Figura 7b).

Figura 7 – Telas do plano de parto detalhado e expectativas para o parto.

a. Tela do plano de parto detalhado.

b. Tela de expectativas para o parto.

The image displays two mobile application screens with a purple-themed interface.

Screen a: Plano de parto detalhado

This screen features a back arrow and the title "Plano de parto detalhado". It contains two main sections:

- Identificação:** A form with fields for "Nome da gestante" (filled with "Maria"), "Prefere ser chamada" (filled with "Não informado"), "Idade" (filled with "25"), "Cartão Nacional de Saúde" (filled with "Não informado"), "Local do pré-natal" (filled with "Não informado"), "Profissional" (filled with "Não informado"), and "Telefone" (filled with "Não informado"). Below these fields is a purple "Editar" button.
- Minha história:** A section with three tabs: "Gestações", "Partos", and "Abortos". Each tab has a button labeled "Sem dados". Below the tabs is a text input field labeled "História das gestações anteriores".

Screen b: Expectativas para o Parto

This screen features a back arrow and the title "Expectativas para o Parto". It contains a section titled "Você gostaria de ..." with several questions, each followed by three buttons: "Sim", "Não", and "Não sei".


- Ter um acompanhante?
- Raspar os pelos íntimos?
- Fazer lavagem intestinal?
- Ter um ambiente com pouca luminosidade?
- Ouvir música?
- Beber líquidos
- Registrar com fotos ou filmagens?

At the bottom of this section is a purple "Salvar" button.

Fonte: Autoria Própria (2024).

O módulo perfil (Figura 8) permite à usuária, a partir da tela principal do perfil (Figura 8a), visualizar e editar seus dados pessoais que, em conjunto com os dados de outras pessoas cadastradas, possibilitará o sistema traçar um perfil socioeconômico (Figura 8b). Quanto maior o volume de dados cadastrados, maiores serão as chances de os modelos de aprendizado de máquina preditivo e/ou descritivo terem um desempenho elevado, que poderá permitir uma maior assertividade nas tomadas de decisões por parte dos profissionais no contexto desta pesquisa.

Figura 8 – Telas do perfil.



Fonte: Autoria Própria (2024).

Como o projeto desenvolvido foi baseado inicialmente em um pedido real, certamente haveria a necessidade das validações necessárias da solicitante para que o aplicativo pudesse ser colocado em produção. Todavia, como o tempo a ser dispendido para reunir dados suficientes com a finalidade de criar um *dataset* com boa representatividade estaria além do prazo estabelecido para a conclusão deste trabalho, os dados utilizados no aplicativo foram gerados empiricamente a partir de entradas randômicas. É importante ressaltar, que mesmo sendo aleatório, houve a preocupação de considerar alguns pontos lógicos, como por exemplo, impedimento de entrada de dados cadastrais de uma pessoa com idade de 15 anos e que tenha um estado civil de casada.

Para este trabalho, foram extraídas no total sete características de interesse, sendo elas: idade, escolaridade, renda familiar, estado civil, número de gestações, número de partos e número de abortos. Os demais dados não contribuíam necessariamente para a criação do perfil das gestantes, tratava-se apenas de informações relacionadas a preferências e informações para auxílio da grávida.

O processo de criação do *dataset* ocorreu com o uso da biblioteca Random do *Python* no *Google Colab* para implementar a criação randômica de diferentes registros. Para cada característica de um registro foi atribuído um valor, simulando resposta fornecida por uma usuária. A fim de criar um conjunto de dados substancial, executou-se esse procedimento em um *loop* de 10.000 repetições.

No laço de repetição, inicialmente selecionou-se a idade em um número inteiro entre 10 e 60, que serviu de limite para as opções de nível de escolaridade, estado civil e número de gestações. Este último, por sua vez, delimitou a quantidade de partos e abortos. Com isso, foi possível criar um *dataset* com informações desejadas, seguindo uma lógica plausível e evitando possíveis *outliers*. Um breve resumo dos dados gerado está exposto no Quadro 3.

Quadro 3 – *Dataset* gerado.

ID	Idade	Escolaridade	Renda Familiar	Número de Gestações	Número de Partos	Número de Abortos	Estado Civil
0	15	Ensino fundamental incompleto	Entre 1 e 2	0	0	0	Solteiro
1	39	Ensino médio completo	Entre 1 e 2	2	2	0	Solteiro
2	23	Ensino médio completo	Entre 1 e 2	0	0	0	Casado
3	21	Ensino fundamental completo	Entre 3 e 5	1	0	0	União estável
4	58	Ensino Médio Incompleto	Entre 1 e 2	0	0	0	Divorciado
...	...	...	...	...	...	...	...
9995	57	Ensino fundamental incompleto	Entre 2 e 3	2	2	0	União estável
9996	29	Ensino médio completo	Entre 1 e 2	4	2	2	Solteiro
9997	21	Ensino superior completo	Entre 5 e 10	3	0	3	Divorciado
9998	45	Ensino médio incompleto	Até 1	1	1	0	Viúvo
9999	17	Ensino médio completo	Entre 3 e 5	1	1	0	Casado

Fonte: Autoria Própria (2024).

Nota: O valor da renda familiar é dado em termo de quantidade salário-mínimo.

4.3 Tratamento do *Dataset*

Com os dados disponíveis, iniciou-se a etapa de tratamento dos dados para evitar futuros problemas e ineficiências no treinamento do modelo de aprendizagem de máquina. Esse processo foi concentrado em quatro partes: transformação de variáveis categóricas, normalização, análise de correlação e redundância; balanceamento e escalonamento.

Das sete características de interesse, quatro são numéricas e três categóricas, por isso foi necessário aplicar alguma técnica para transformar os valores categóricos em numéricos. As três *features* transformadas foram “Escolaridade” e “Renda familiar”, ambas de natureza ordinal, além do “Estado Civil” de natureza nominal.

Para os atributos ordinais, em que devem ser preservadas a ordem dos valores, foi utilizado o *OrdinalEncoder* do *Scikit-Learn*, onde é estabelecida previamente a ordem hierárquica correspondente a cada elemento e depois a transformação dos dados é realizada. Para o atributo “Estado Civil” cujo valores não apresentam uma relação de ordem hierárquica, foi utilizada a classe *OneHotEncoder*, do *Scikit-Learn*, que transformam as *features* categóricas em várias colunas com valores binários, uma para cada valor único da coluna original.

Feito isso, ocorreu a etapa de normalização do *dataset*, em que se buscou evitar escalas desproporcionais para que o modelo pudesse convergir com maior facilidade e evitar situações como o sobreajuste devido a uma diferença muito brusca. Como os dados foram gerados, não existe a presença de *outliers*, permitindo o uso de uma técnica como o *StandardScaler* do *Scikit-Learn*. A realização dessa etapa foi responsável por transformar todos os dados numéricos, padronizando-os de modo que a média seja zero e o desvio padrão seja um.

Um exemplo de como o *dataset* ficou após esses processos pode ser verificado na Tabela 3, contendo o nome das colunas e os valores.

Tabela 3 – Exemplo do resultado da padronização dos valores do *dataset*.


Coluna	Valor
ID	0
Idade	-1.005922
Escolaridade	-1.299876
Renda Familiar	-0.879639
Número de Gestações	-1.215419
Número de Partos	-0.764090
Número de Abortos	-0.537705
Estado Civil_Casado	0.0
Estado Civil_Divorciado	0.0
Estado Civil_Solteiro	1.0
Estado Civil_União Estável	0.0
Estado Civil_Viúvo	0.0

Fonte: Autoria Própria (2024).

Em seguida, realizou-se um processo de análise para identificar possíveis redundâncias e combinações de variáveis, visando a eliminação de algumas variáveis para otimizar o processo de treinamento. Sendo assim, foi analisado a correlação das *features*, verificando quais são aquelas que possuam uma correlação acima de 0,8 (correlação forte), que podem indicar a redundância entre as variáveis; e aquelas com correlação inferior à -0,8 (correlação fraca), que podem ser irrelevantes para o modelo.

A biblioteca *Pandas* possui a função “*.corr()*”, que foi utilizada para calcular a matriz de correlação, cruzando todas as variáveis e apresentando a correlação. É possível ainda, com o auxílio das bibliotecas *Matplotlib* e *Seaborn*, criar uma representação visual da matriz, facilitando o processo de análise. A matriz de correlação encontrada ao executar esses processos está ilustrada na Figura 9.

Figura 9 – Matriz de correlação entre variáveis.



Fonte: Autoria Própria (2024).

Para auxiliar na busca das altas e baixas correlações, usou-se a biblioteca *Numpy*, que realiza o processamento de funções matemáticas de larga escala em *arrays* e matrizes, possibilitando o seu uso em uma função que filtre as correlações. No caso do *dataset* criado para esta pesquisa, não houve correlações acima de 0,8 ou abaixo de -0,8, sugerindo não haver alta redundância nos atributos utilizados.

Por fim, houve a checagem de balanceamento e escalonamento. O primeiro é responsável por verificar a distribuição dos valores, identificando possível existência de uma grande discrepância entre eles, como uma quantidade muito baixa ou muito alta em relação aos outros. Essa verificação evita que certos vieses sejam criados, tendenciando o modelo a determinada ação.

O comando “*.value_counts()*” da biblioteca Pandas auxilia na obtenção de cada valor único e suas quantidades para análise. A Tabela 4 mostra a quantidade de registros por valor para os atributos “escolaridade” (Tabela 4a), “renda familiar” (Tabela 4b) e “número de gestações” (Tabela 4c), indicando que apesar de haver alguma discrepância entre as quantidades, o *dataset* ainda se encontra suficientemente balanceado.

Tabela 4 – Balanceamento dos registros por valor de atributo.

4a. Atributo escolaridade.		4b. Atributo renda familiar.		4c. Atributo número de gerações	
Valor	Quantidade	Valor	Quantidade	Valor	Quantidade
-1.299876	1856	-0.292783	1711	-0.350598	4139
-0.783499	1813	0.880930	1688	-1.215419	2191
-0.267122	1809	-1.466495	1660	0.514222	1809
0.249255	1301	-0.879639	1653	1.379043	1147
0.765632	1257	1.467786	1649	2.243864	714
1.798386	991	0.294074	1639		
1.28200	973				

Fonte: Autoria Própria (2024).

O escalonamento, neste caso, é mais uma verificação se a etapa de padronização executada anteriormente está correta, coletando a média, desvio padrão, valor máximo e valor mínimo das colunas especificadas. O resultado apresentado na Tabela 5 demonstra que os valores estão ajustados de maneira proporcional.

Tabela 5 – Escalonamento das características.

Info	Idade	Número de Gestações	Número de Partos	Número de Abortos	Escolaridade	Renda Familiar
<i>mean</i>	-2.84217e-18	-6.69687e-17	5.25802e-17	-4.97380e-17	-2.84217e-17	7.46070e-17
<i>std</i>	1.00005e+00	1.00005e+00	1.00005e+00	1.00005e+00	1.00005e+00	1.00005e+00
<i>min</i>	-1.39890e+00	-1.215420e+00	-7.64090e-01	-5.37705e-01	-1.29988e+00	-1.46650e+00
<i>max</i>	2.53085e+00	2.24386e+00	3.59653e+00	5.45678e+00	1.79839e+00	1.46779e+00

Fonte: Autoria Própria (2024).

4.4 Escolha do Algoritmo

O *dataset* gerado não apresenta necessariamente um atributo alvo, que possa revelar se uma determinada gestante abandonou ou continuou o seu pré-natal. Essa característica da ausência do *target* induz que os algoritmos de aprendizagem a serem aplicados devam ser não-supervisionados. Deste modo, para a fase experimental do projeto foram explorados cinco algoritmos diferentes: *K-means*, *Density-Based Spatial Clustering of Applications with Noise* (DBSCAN), *Gaussian Mixture Model* (GMM), Rede Neural *Autoencoder* e *Self-Organizing Maps* (SOMs).

O *K-means* é um método de agrupamento que forma *clusters* de acordo com a proximidade das instâncias com o centro de determinado *cluster*. A escolha desse método é recomendada, principalmente, quando existe claramente uma separação entre os grupos, sendo bastante simples, mas precisando ter uma ideia da quantidade de *clusters* para aumentar a eficiência.

O DBSCAN, por sua vez, caracteriza-se pelo agrupamento conforme a densidade de pontos em certa região, onde a formação dos *clusters* ocorre levando em consideração o limite de distância e densidade. Essa técnica consegue lidar melhor com formas irregulares de agrupamentos, bem como pontos fora do comum no espaço n -dimensional, em que n é a quantidade de atributos.

Ao considerar a formação de *clusters* não esférico, com maior capacidade de diferenciação entre eles no que diz respeito a tamanho e densidade, o GMM é uma excelente alternativa, sendo capaz de determinar probabilidades de pertencimento, ainda que limitados apenas para agrupamentos *gaussianos*.

Os *autoencoders* são redes neurais que aprendem representações eficientes dos dados, conseguindo reconstruir os padrões. Um de seus usos é extrair características latentes, o que possibilitaria uma melhora na eficiência do modelo gerado, ainda que seja preciso aplicar em conjunto com outro método de agrupamento.

As SOMs são uma rede neural capaz de reduzir a dimensionalidade dos dados, bem como possibilitar a visualização de dados complexos. É uma alternativa para melhorar as entradas antes de passar por um outro algoritmo de agrupamento.

Por fim, o *Principal Component Analysis* (PCA) é um algoritmo de aprendizagem não-supervisionado cuja função neste trabalho foi exclusivamente para auxiliar na redução de dimensionalidade (número de atributos) permitindo uma visualização gráfica dos pontos, contribuindo para a análise dos outros algoritmos.

4.5 Treinamento do Modelo


4.5.1 *K-means*

O treinamento com o algoritmo *K-means* começa com a busca da quantidade ideal de *clusters* que serão formados. Para isso, aplicou-se o “Método do Cotovelo”, que plota o valor da *inertia* pelo número de *clusters*. A *inertia* é uma medida de compactação ou coerência dos agrupamentos, por isso, busca-se por valores mais baixos, já que seriam mais bem definidos.

Outra medida importante, baseada na coesão e separação dos *clusters*, é o Coeficiente *Silhouette*. Essa medida varia de -1 a 1, em que o valor mais negativo significa que os pontos estão mal agrupados, um valor próximo a zero indica proximidade a fronteira do agrupamento, e valor próximo a 1 representa que os *clusters* possuem melhor separação e densidade.

É possível calcular os valores para essa medida utilizando o próprio *Scikit-Learn*, com a classe *K-means*. Ao executar um *loop* com diferentes números de *clusters*, fez-se o uso da biblioteca *Matplotlib* para plotar os dados nos gráficos presentes na Figura 10.

Figura 10 – Método do cotovelo e coeficiente *silhouette* usando *K-means*.



Fonte: Autoria Própria (2024).

Observando os gráficos, percebe-se que pelo método do cotovelo, o ponto 3 é onde a inercia começa a reduzir menos significativamente, sendo que este mesmo ponto 3 é o ponto de maior valor do Coeficiente *Silhouette*. Sendo assim, este valor foi utilizado como o número de *clusters* para o agrupamento ideal. Com isso, temos os dados necessários para treinar o modelo, usando novamente a classe *KMeans*, colocando os dados tratados junto ao número de *clusters*.

4.5.2 DBSCAN


O algoritmo DBSCAN foi inicialmente utilizado de sua forma padrão que já apresentara alguns resultados interessantes, sendo alterado posteriormente os parâmetros “*eps*” e “*min_samples*”, que se referem, respectivamente, a distância máxima entre duas amostras para serem considerados vizinhos e o número mínimo de amostras para pertencer a um agrupamento.

O treinamento em si ocorre com o uso do DBSCAN presente no *Scikit-Learn*. As variáveis mencionadas acima são iniciadas com valores de “*eps* = 0.5” e “*min_samples* = 5” e depois utiliza-se o *dataset* tratado para realizar o treinamento.

4.5.3 GMM

Ao trabalhar com este algoritmo, a etapa inicial consistiu em determinar o número de *clusters* a serem considerados, assim como foi com o K-means. Para isso, os critérios *Akaike Information Criterion* (IAC) e *Bayesian Information Criterion* (BIC) foram usados para avaliar os modelos. Ao obter suas medidas com diferentes números de *clusters* é possível identificar o de melhor desempenho. O valor escolhido normalmente serão aqueles com os menores valores. O *GaussianMixture* do *Scikit-Learn* possui funções próprias que calculam esses valores. Ao aplicar no conjunto de dados tratado, obteve-se o resultado apresentado na Figura 11.

Figura 11 – Critérios AIC e BIC do modelo GMM.



Fonte: Autoria Própria (2024).

4.5.4 Rede Neural *Autoencoder*

Fazendo uso da biblioteca *Tensorflow*, especificamente a parte do *Keras*, onde estão todas as classes mencionadas posteriormente para a aplicação dos *Autoencoders*, foi estabelecida uma camada de *Input* dos dados, com o *shape* do *dataset*. Em seguida, foi criado um modelo que teve uma camada do tipo *Dense* com ativação “*sigmoid*” para realizar a reconstrução dos dados.

Os dados passaram por esse primeiro modelo antes de serem utilizados por outro composto por uma camada *Dense* com ativação “*relu*”. Especificamente, para este trabalho, a representação latente foi extraída para ser utilizada por alguns dos outros algoritmos de agrupamento.

4.5.5 SOMs


Para este procedimento, houve a necessidade de uma etapa a mais de tratamento com a finalidade de atender as características do algoritmo, ocorrendo a aplicação do *MinMaxScaler* do *Scikit-Learn* que transforma os valores dentro de um intervalo específico. Posteriormente, utilizou-se a biblioteca *Minisom* que possui o SOM para uso, sendo definido os valores de “x” e “y” que formam o *shape*, o “*input_len*” que demonstra o número de dimensões de entrada, o “*sigma*” referente ao tamanho inicial da vizinhança e o “*learning_rate*” responsável pela taxa de aprendizado.

Após a realização do procedimento anterior, atribui-se ao modelo os pesos iniciais de acordo com o *dataset* e, posteriormente, o modelo foi treinado com os dados, sendo estabelecido um número finito de iterações. Para este caso específico foi atribuído o valor 1000 para a quantidade de iterações que deveria ser processada. Da mesma forma como os *Autoencoders*, os dados obtidos foram usados pelos algoritmos de agrupamento com a intenção de formar os clusters.

4.6 Teste do Modelo

4.6.1 *K-means*

Após o treinamento, o modelo armazena na variável “*labels*” o resultado do agrupamento encontrado. Com a utilização do PCA, os dados foram reduzidos para duas dimensões, sendo diferenciados de acordo com os rótulos obtidos. A Figura 12 apresenta a visualização da redução do agrupamento dos dados, que foi plotada com o auxílio do *Matplotlib*.


Figura 12 – Resultado do *K-means*.

Fonte: Autoria Própria (2024).

4.6.2 DBSCAN

Após concluído o treinamento, obteve-se as *labels* de cada ponto. A partir disso, existem possibilidade de conseguir mais informações como, por exemplo, o número de *clusters* e ruídos, que foram respectivamente 338 e 6211. A existência desses ruídos acaba por impactar na visualização do resultado, que pode ser obtida por meio do *Matplotlib*, que neste caso resultou na ilustração contida na Figura 13. Salienta-se que, para fins visuais, as legendas foram cortadas.

Figura 13 – Resultado com DBSCAN.




Fonte: Autoria Própria (2024).

4.6.3 GMM

O GMM, por sua vez, é bastante simples, seguindo um procedimento semelhante ao realizado pelo *K-means*, de modo que é possível obter os rótulos aplicados a cada um dos pontos, que juntamente com os dados originais foram usados como base para aplicação no PCA e *Matplotlib*. O resultado do agrupamento obtido a partir do GMM está exposto na Figura 14.

Figura 14 – Resultado com GMM.




Fonte: Autoria Própria (2024).

4.6.4 Rede Neural Autoencoder

Ao passar os dados pela rede treinada, os resultados foram as representações latentes utilizadas como entrada para os três algoritmos expostos anteriormente (*K-means*, DBSCAN, GMM).


Para todos os algoritmos, procedeu-se com os mesmos processos já explicados. Em relação ao *K-means*, o resultado do agrupamento está plotado na Figura 15, enquanto a Figura 16 corresponde a visualização obtida pelo método DBSCAN e, por fim, com o uso do GMM originou-se a Figura 17.

Figura 15 – Resultado com o *Autoencoder + K-means*.




Fonte: Autoria Própria (2024).

Figura 16 - Resultado com o *Autoencoder + DBSCAN*.



Fonte: Autoria Própria (2024).

Figura 17 - Resultado com o *Autoencoder* + GMM.




Fonte: Autoria Própria (2024).

4.6.5 SOMs

Com o algoritmo SOMs, o processo foi semelhante a dos *Autoencoders*, ou seja, após realizado o treinamento, uma vez que os dados percorreram o modelo, obteve-se os valores dos pesos que podem ser transformados para servir de entrada para os algoritmos de agrupamento.


Conforme já explicado, os passos foram repetidos até que os resultados fossem plotados. Com o auxílio do PCA e do *Matplotlib* os agrupamentos foram gerados por meio do *K-means*, DBSCAN e GMM, e os resultados estão ilustrados nas Figuras 18, 19 e 20, respectivamente.

Figura 18 – Resultado com o SOM + *K-means*.




Fonte: Autoria Própria (2024).

Figura 19 – Resultado com o SOM + DBSCAN.



Fonte: Autoria Própria (2024).

Figura 20 – Resultado com o SOM + GMM.



Fonte: Autoria Própria (2024).

4.7 Aperfeiçoamento do Modelo

Por meio da análise visual de todos os resultados obtidos, é notório que alguns apresentaram um agrupamento melhor do que outros. Entretanto, para confirmar essa percepção, pode ser realizada a coleta e comparação do coeficiente da silhueta porque é um dos métodos disponíveis e facilmente implementáveis.

O coeficiente da silhueta resulta de um cálculo que mede quão bem uma determinada instância se encaixa no *cluster* definido em relação aos *clusters* vizinhos, de modo que é possível caracterizar bem a separação e a coesão interna dos *clusters* identificados. Por isso, pode-se afirmar, que se trata de uma excelente forma para definir, de maneira geral, a qualidade do agrupamento encontrado.

Ao aplicar a classe *SilhouetteScore* do *Scikit-Learn*, foram obtidos os valores dos coeficientes de cada modelo implementado. O valor do *SilhouetteScore* de cada algoritmo de está exposto na Tabela 6.

Tabela 6 – Qualidade do agrupamento de cada algoritmo medido por *SilhouetteScore*.

Algoritmo	<i>SilhouetteScore</i>
K-means	0,2401
DBSCAN	0,5205
GMM	0,0417
Autoencoder + K-means	0,1359
Autoencoder + DBSCAN	0,6618
Autoencoder + GMM	0,0300
SOMs + K-means	0,4823
SOMs + DBSCAN	0,5314
SOMs + GMM	0,3858

Fonte: Autoria Própria (2024).

Para entender a pontuação, deve-se primeiramente saber que o valor para essa medida varia de -1 a 1, em que os valores mais negativos correspondem a uma clusterização considerada incorreta; valor em torno de zero indica a ocorrência de sobreposição de diferentes *clusters*, e os valores próximos a 1 são os mais interessantes, pois descrevem um agrupamento denso e bem separado.

Os algoritmos que melhor tiveram melhores performances foram os que utilizaram o DBSCAN e o SOMs. Entretanto, é necessário ressaltar que as pontuações referentes ao DBSCAN foram feitas com base apenas nos dados com *clusters*, sendo que foram desconsiderados os ruídos. Por essa razão, mesmo que aparentemente tenham sido registrados os valores maiores no *SilhouetteScore*, isso podem não necessariamente traduzir em um bom agrupamento devido ao descarte quantitativo das entradas.


Sendo assim, o foco do aperfeiçoamento dos modelos foi dividido em duas partes: DBSCAN e SOMs. O primeiro buscou-se reduzir os ruídos e melhorar a formação dos agrupamentos, enquanto o último caracterizou-se por aumentar o número de épocas de treinamento e pela troca dos otimizadores.

4.7.1 DBSCAN

A primeira etapa foi utilizar o algoritmo *NearestNeighbors* do *Scikit-Learn* para verificar qual seria o melhor valor para inserir no parâmetro *eps*, que indica a distância máxima entre duas amostras para serem consideradas vizinhas. Ao colocar as informações obtidas de forma visual, obtém-se um comparativo entre a distância até o número determinado de vizinhos e a quantidade de pontos ordenados.

Ao testar diferentes valores de número de vizinhos, não houver diferenças significativas, portanto, foi estabelecido o número padrão de cinco vizinhos e, com o auxílio do *Matplotlib* foi obtido o gráfico exposto na Figura 21. A curva começa a ficar mais acentuada a partir da distância 1, que por isso os valores próximos a ele foram testados como valor de *eps*.

Figura 21 – Aplicando o *NearestNeighbors* para descobrir o valor de *eps*.




Fonte: Autoria Própria (2024).

O modelo realizado na etapa anterior, cuja pontuação da silhueta foi 0,5205, obteve 338 *clusters*, porém o número de pontos classificados como ruídos foi de 6211, sendo 62,11% do *dataset*, indicando que a maior parte das informações foi descartada, o que reduz a significância desse resultado.

Ao aplicar as mudanças em relação ao parâmetro *eps*, o melhor resultado obtido usou o valor de 1,25, gerando um total de 34 agrupamentos com 369 pontos de ruído. Apesar da diminuição significativa dos ruídos, de 62,11% para 3,69%, o *SilhouetteScore* também sofreu uma grande redução, com pontuação cerca de 0,0326, demonstrando uma grande sobreposição dos *clusters*, confirmado visualmente na Figura 22, ao expor a visualização em duas dimensões.

Figura 22 – Resultado com o DBSCAN atualizado.




Fonte: Autoria Própria (2024).

Outro resultado interessante mostrado anteriormente, que merece uma atenção especial, foi aquele com pontuação de 0,6618 obtido pelo algoritmo *Autoencoder* com o DBSCAN, mas que também contava com elevada quantidade de ruídos correspondente a 74,54% do *dataset*. Por esse motivo, repetiu-se os mesmos processos anteriores, sendo que a diferença foi nos valores utilizados nos parâmetros de entrada, que corresponderam aos dados obtidos por meio da rede neural.

Seguindo os mesmos procedimentos já relatados no cenário anterior, verificou-se os vizinhos mais próximos, sendo que a quantidade de vizinhos não demonstrou grande influência sobre o resultado obtido, por isso foi considerado o número de vizinhos como cinco. A Figura 23 mostra a relação entre a quantidade de pontos ordenados com a distância em relação aos vizinhos.


A partir disso, percebeu-se que os valores próximos a 2,8 representavam o momento em que a curva se tornou mais acentuada. Diante deste contexto, testou-se diferentes valores, de modo que o melhor resultado obtido para *eps* foi igual a 3, que retornou 18 *clusters* e 127 pontos de ruído, com o valor de *SilhouetteScore* igual a 0,1359. A visualização 2D desses resultados pode ser conferida na Figura 24.

Figura 23 - Valor de *eps* com os dados do *Autoencoder* a partir do *NearestNeighbors*.



Fonte: Autoria Própria (2024).

Figura 24 - Resultados com *Autoencoder* + DBSCAN atualizado.



Fonte: Autoria Própria (2024).

A seguir será exposto o resultado gerado a partir da combinação entre o DBSCAN e a rede neural SOMs.

4.7.2 SOMs

O algoritmo *MiniSom* possui diversos parâmetros que interferem na performance, como o formato do mapa, a taxa de aprendizado, o número de interações, a função de redução da taxa de aprendizado, a função dos vizinhos, entre outras. Os parâmetros mencionados tiveram seus valores alterados a fim de buscar aqueles que pudessem proporcionar os melhores resultados.

O número de neurônios do mapa pode ser definido pela Equação 1:

$$N = 5 * \sqrt{n} \quad (1)$$

onde: n = número de amostras.


No experimento realizado foram consideradas 10000 amostras, que resulta em 500 neurônios. O mapa de neurônios deve representar valores de X e Y que aproximem desse número quando multiplicados. Após os testes, os valores escolhidos foram $X = 25$ e $Y = 20$.

Outro parâmetro alterado foi o número de iterações, sendo testados valores em um intervalo de 1000 a 10000. Apesar de não terem sido registradas grandes diferenças, o valor final escolhido foi de 3000 iterações. De maneira geral, as outras variáveis não apresentaram melhoras ao serem alteradas, sendo que em alguns casos, certas funções de vizinhança, ou funções de redução prejudicaram a performance, por isso, foram mantidos os valores padrões.

Após os dados serem transformados com esse novo modelo, eles foram utilizados como entradas para os algoritmos de agrupamento utilizados neste trabalho, em que cada um seguiu os mesmos processos já abordados anteriormente.

Para o *K-means*, a pontuação silhueta final foi de aproximadamente 0,4823, o mesmo valor observado antes da alteração dos hiper parâmetros. Mesmo que haja diferenças, elas são bem pequenas, inclusive foi obtido um gráfico (Figura 25) parecido ao anterior.

Figura 25 - Resultado com o SOM + *K-means* atualizado.




Fonte: Autoria Própria (2024).

Em relação ao DBSCAN, embora as melhorias vistas na seção anterior tenham sido aplicadas, ao utilizar os dados resultantes do uso do SOM o algoritmo não conseguiu agrupar *clusters* suficientes para a utilização, tendo havido apenas um agrupamento identificado e o restante foram ruídos. Isso mostra que as alterações na rede neural não foram bem aceitas pelo algoritmo de agrupamento.

Por fim, considerando o GMM, as modificações apresentaram sim uma melhora, conforme o valor da *SilhouetteScore* igual a 0,4823. A representação visual, por sua vez, não demonstrou tantas alterações, como pode ser visto na Figura 26.

Figura 26 - Resultado com o SOM + GMM atualizado.



Fonte: Autoria Própria (2024).

As comparações entre os resultados anteriores ao aperfeiçoamento dos modelos com os obtidos após serem aperfeiçoados podem ser feitas a partir dos dados dispostos na Tabela 7. Vale lembrar que os valores originais, quando usado o DBSCAN, apresentavam ruídos com mais de 50% dos dados, enquanto no modelo atualizado os ruídos ficaram abaixo de 5%.

Tabela 7 – Taxa de ruídos nos dados identificados pelos modelos originais e aperfeiçoados.

Algoritmo	<i>SilhouetteScore</i> Original	<i>SilhouetteScore</i> Atualizado
DBSCAN	0,5205	0,0326
Autoencoder + DBSCAN	0,6618	0,1359
SOMs + K-means	0,4823	0,4823
SOMs + DBSCAN	0,5314	-
SOMs + GMM	0,3858	0,4823

Fonte: Autoria Própria (2024).

Nota: O algoritmo SOMs + DBSCAN gerou só um cluster no modelo aperfeiçoado.

4.8 Avaliação do Modelo

Inicialmente, para fazer a avaliação dos modelos, baseou-se em três medidas: a *SilhouetteScore*, o Índice de Dunn e o Índice de Davies-Bouldin. Como o primeiro já foi comentado anteriormente, será explicado um pouco mais dos outros dois.

O Índice de Dunn faz uma relação entre o diâmetro de um *cluster* com a distância mínima entre *clusters* diferentes, de forma que, quanto maior o valor, mais separados e compactos são os agrupamentos. Por sua vez, o Índice de Davies-Bouldin verifica a dispersão dos agrupamentos e separação dos *clusters*, de maneira que valores menores correspondem a uma qualidade maior.

Sabendo disso, foram coletadas as pontuações desses três indicadores para os algoritmos vistos, com os valores estando dispostos na Tabela 8.

Tabela 8 – Avaliação da qualidade do agrupamento gerado por diferentes algoritmos.

Algoritmo	<i>SilhouetteScore</i>	Índice de Dunn	Índice de Davies-Bouldin
DBSCAN	0,0326	0,0626	1,8031
Autoencoder + DBSCAN	0,1359	0,1811	1,8728
SOMs + K-means	0,4823	0,6375	0,9069
SOMs + DBSCAN	-	-	-
SOMs + GMM	0,4823	0,0078	1,9738

Fonte: Autoria Própria (2024).

Conforme exposto, o modelo que apresentou os maiores valores na *SilhouetteScore* e no Índice de Dunn e o menor no Índice de Davies-Bouldin foi aquele criado a partir da rede neural SOM com o K-*means*.

Estabelecido o melhor modelo, foi explorado algumas informações estatísticas para entender como os agrupamentos relacionavam-se a outros dados. A utilização da biblioteca Pandas foi de grande ajuda para obter esses dados, como com o uso da função “*value_counts()*” especificando a coluna dos clusters, que retorna a quantidade de valores únicos diferentes, cujo resultado pode ser observado na Tabela 9.

Tabela 9 – Quantidade de elementos em cada cluster.

Cluster	Quantidade
1	3602
3	1610
2	1599
4	1595
0	1594

Fonte: Autoria Própria (2024).

Outra função utilizada foi o “*groupby().mean()*”, que agrupa os elementos do *DataFrame* de acordo com a coluna especificada e depois exibe a média para cada elemento único, conforme verificado na Tabela 10. Os nomes das colunas correspondem de acordo com o valor: 1 - Idade; 2 - Escolaridade; 3 - Renda Familiar; 4 - Número de Gestações; 5 - Número de Partos; 6 - Número de Abortos; 7 - Estado Civil_Casado; 8 - Estado Civil_Divorciado; 9 - Estado Civil_Solteiro; 10 – Estado Civil_União Estável e 11 - Estado Civil_Viúvo.

Tabela 10 – Média dos valores de cada coluna filtrados por cluster.

<i>Cluster</i>	1	2	3	4	5	6	7	8	9	10	11
0	0,268	0,169	-0,038	0,091	0,051	0,016	0,0	0,0	0,0	0,0	1,0
1	-0,497	-0,317	0,017	-0,202	-0,097	-0,097	0,0	0,0	1,0	0,0	0,0
2	0,282	0,183	0,025	-0,099	0,059	0,059	1,0	0,0	0,0	0,0	0,0
3	0,299	0,155	-0,026	0,117	0,073	0,073	0,0	1,0	0,0	0,0	0,0
4	0,262	0,207	-0,001	0,147	0,070	0,070	0,0	0,0	0,0	1,0	0,0

Fonte: Autoria Própria (2024).

Percebe-se que os atributos resultantes dos valores do estado civil descrevem de forma precisa as informações de cada grupo constituído, de modo que os demais atributos se torna pouco relevante.

5. CONSIDERAÇÕES FINAIS

A proposta inicial do trabalho foi a criação de uma ferramenta capaz de auxiliar os estabelecimentos da área da saúde a promover um melhor tratamento e acompanhamento às gestantes. Para isso, escolheu-se como abordagem o desenvolvimento de um modelo de aprendizado de máquina capaz de analisar e expor os perfis de grávidas com maior probabilidade de abandonar o pré-natal.

Considerando que o elemento essencial para a elaboração de um modelo de aprendizado de máquina são os dados, a preocupação inicial foi determinar como eles seriam obtidos. No final, foi realizado o desenvolvimento de um aplicativo para dispositivos *Android* capaz de auxiliar as gestantes no acompanhamento dos dados referentes à gravidez dela e, armazenando tais dados junto a outros estipulados no cadastro para coletar as informações necessárias conforme o uso.

Embora o aplicativo tenha sido desenvolvido sobre a forma de um mínimo produto viável, o fato dele ter sido solicitado por outro indivíduo que objetiva a aplicação real impossibilitou a finalização e implantação do mesmo em cenário real, já que seria necessário tratar a respeito dos detalhes faltantes, bem como providenciar adequações éticas e de proteção de dados, medidas indispensáveis para execução e legalidade.

Desse modo, a fim de que o trabalho de desenvolvimento não fosse desperdiçado e em razão das limitações da utilização de *datasets* pré-existentes na *Internet*, a obtenção dos dados ocorreu pela geração deles em conformidade com os aspectos especificados no aplicativo, como as informações e os diferentes valores possíveis. O processo de geração não foi completamente aleatório, pois foram consideradas algumas regras lógicas para simular a realidade com o máximo de precisão.

Ainda que os dados tenham sido criados, foi imprescindível uma etapa de tratamento deles, para que fossem adequados para a utilização em diferentes algoritmos e com maiores probabilidades de performar. Para isso, foram utilizados vários métodos disponíveis no *Scikit-Learn*, sendo inicialmente feita a transformação de dados categóricos em dados numéricos, para que fossem usados no treinamento dos modelos. Neste caso, foram adotadas duas abordagens que correspondessem à necessidade de preservar a noção de ordem hierárquica ou não, aplicando, respectivamente, o *OrdinalEncoder* ou o *OneHotEncoder*.

Posteriormente, fez-se uso do *StandardScaler* para padronizar todos os dados, evitando diferenças drásticas entre os intervalos que pudessem perturbar ou sobreajustar posteriormente o modelo. Depois de garantir que as correlações entre as características do *dataset* não fossem irrelevantes ou redundantes, bem como verificar se as amostras estão balanceadas para evitar o

tendenciamento do modelo e confirmar o escalonamento correto dos dados, o *dataset* ficou pronto para serem utilizados pelos algoritmos.

Em virtude das limitações do *dataset*, como o fato de não haver uma coluna que indique caso a gestante abandone ou não o pré-natal, o trabalho foi consequentemente direcionado para uma abordagem não-supervisionada. Houve três algoritmos de agrupamento aplicados durante o trabalho: *K-means*, DBSCAN e GMM. Além disso, foram testadas duas redes neurais, sendo elas as *Autoencoders* e as SOMs, como etapa a mais de processamento de dados para tentar melhorar as respostas dos algoritmos de agrupamento.

Após a aplicação de diversas técnicas específicas para cada modelo, foram reduzidos os algoritmos para a etapa de “*fine tuning*” por meio da avaliação da *SilhouetteScore*. Os algoritmos que passaram para a próxima etapa foram todas as situações envolvendo o DBSCAN e SOMs. Mesmo que inicialmente o desempenho dos modelos que utilizaram o DBSCAN pareciam ter maior qualidade de agrupamento, essa característica mostrou-se conflitante porque estava sendo avaliado apenas dados classificados em um *cluster*, ignorando os ruídos que correspondiam mais da metade dos dados.

Para diminuir os ruídos, os hiperparâmetros foram alterados. Embora os ruídos tenham sido reduzidos, a qualidade do agrupamento foi diretamente afetada, visto que os *clusters* ficaram sobrepostos e sem separação. Por sua vez, ao utilizar o “*fine tuning*” no SOMs, houve resultados divergentes de acordo com o algoritmo de *clusterização* usado em conjunto, para o *K-means* praticamente não alterou o desempenho, para o DBSCAN impossibilitou a formação de *clusters* e para o GMM melhorou a performance em relação ao anterior.

Após esse procedimento, foram buscadas algumas métricas para avaliar esses modelos melhorados, sendo elas a própria *SilhouetteScore*, o Índice de Dunn e o Índice de Davies-Bouldin, que de maneira geral permitiram uma avaliação dos agrupamentos quanto a densidade, delimitação, separação e dispersão. Entre todos os modelos, aquele de maior desempenho nessas métricas foi a utilização da rede neural SOMs junto com o *K-means*.

Uma vez descoberto o modelo de melhor desempenho, buscou-se relacionar os agrupamentos formados com os dados iniciais do *dataset* para verificar quais relações podiam ser entendidas, bem como se o problema principal poderia ser respondido, qual seja: qual o perfil de gestante com maior propensão ao abandono do pré-natal? Aplicando as técnicas, verificou-se que a distribuição da quantidade de *clusters* foi bastante equivalente (cerca de 1600 amostras) com exceção de um deles que apresentou quase o dobro dos outros (cerca de 3200 amostras).

Também foi possível analisar a média dos valores de cada atributo para cada agrupamento formado, que trouxe algumas informações relevantes que podem ser traduzidas nesses aspectos:

- **Cluster 0:** Idade, escolaridade, número de gestações, partos e abortos próximas da média geral; renda abaixo da média; composto inteiramente por viúvos.
- **Cluster 1:** Idade, escolaridade, número de gestações, partos e abortos abaixo da média; renda familiar acima da média; compostos por solteiros.
- **Cluster 2:** Idade, escolaridade e renda um pouco acima da média; número de gestações abaixo da média; número de partos e abortos na média; composto exclusivamente por casados.
- **Cluster 3:** Idade, número de gestações, partos e abortos um pouco acima da média geral; escolaridade na média; renda familiar abaixo da média geral; todos divorciados.
- **Cluster 4:** Idade, escolaridade, número de gestações, partos e abortos acima da média geral; renda familiar abaixo da média; todos em união estável.

Mesmo que tenha sido encontrado algumas outras características próprias de cada *cluster*, a preocupação maior é o fato de que os dados referentes ao estado civil da gestante foram exclusivos para cada agrupamento, ou seja, cada *cluster* apresentou um único estado civil. Portanto, pode-se concluir que este fator tenha sido possivelmente o principal determinante da formação dos agrupamentos, mas essa característica não é capaz de, só com sua presença, afirmar que a grávida vai abandonar ou não o pré-natal.

Embora não existam dados rotulados para fazer uma validação externa, as informações obtidas demonstram que as técnicas utilizadas não conseguiram formar grupos capazes de solucionar o problema do trabalho, seja por uma questão de ausência de dados reais que tenham uma correlação maior entre as características, seja por as características escolhidas não conseguirem extrair a informação requerida.

Em caso de terem sido encontrados *clusters* bem definidos com a identificação clara da combinação dos valores dos diferente atributos originais poderia, a partir dos resultados de outros trabalhos como de Rosa, Silveira e Costa (2014), identificar possíveis grupos de grávidas que tenham o perfil com maiores chances de abandonar o pré-natal.

Salienta-se que a principal limitação desta pesquisa está relacionada ao *dataset*, já que os dados reais que eram representativos em relação à região são informações sensíveis e, portanto, não acessíveis. Além disso, ressalta-se que em decorrência do tempo limitado e pendência de aprovação do solicitante, não foi possível disponibilizar o aplicativo para a coleta

dos dados reais junto às potenciais usuárias do mesmo, levando a necessidade de seguir a alternativa tomada durante o trabalho.

As principais contribuições deste trabalho estão relacionadas aos aspectos tecnológicos, científicos, sociais e econômicos. Com o desenvolvimento do aplicativo para dispositivos *Android* destinadas para pessoas grávidas, as mulheres serão capazes de fazer um cadastro e inserir informações sobre a sua gestação. Cientificamente, este trabalho comprova que os dados a serem armazenados pelo *app* podem ser usados por algoritmos de aprendizado de máquina para gerar modelos preditivos capazes de prever se uma gestante abandonará ou não os atendimentos pré-natal. Evitar a descontinuidade do acompanhamento pré-natal, não somente traz benefícios sociais para a mãe e sua família, como também reduz gastos na área da saúde em decorrência da prevenção de possíveis complicações na gravidez.

Por fim, sugere-se para trabalhos futuros a utilização dos dados reais para a formulação de novos modelos, pois dessa forma será possível verificar ligações reais existentes entre as *features*, bem como validar externamente os resultados. Com dados completos é possível ainda seguir com uma abordagem supervisionada, para a qual existe uma larga abrangência de algoritmos que podem representar melhor a situação vivenciada e resolver o problema.

REFERÊNCIAS

- AGRAWAL P. Maternal mortality and morbidity in the United States of America. **Bulletin of the World Health Organization**, v. 93, n. 3, p. 135, 2015. Disponível em: <https://pmc.ncbi.nlm.nih.gov/articles/PMC4371496/> Acesso em: 13 set. 2024.
- ALESSANDRIA, S. **Flutter Projects: A practical, project-based guide to building real-world cross-platform mobile applications and games**. Editora Packt Publishing. 2020.
- AMERSHI, S.; BEGEL, A.; BIRD, C.; DELINE, R.; GALL, H.; KAMAR, E.; NAGAPPAN, N.; NUSHI, B.; ZIMMERMANN, T. Software engineering for machine learning: A case study. *In: International Conference on Software Engineering: Software Engineering in Practice (ICSE-SEIP)*, 41, 2019, **Proccedings** [...]. IEEE, p. 291-300, 2019.
- AMORIM, B.; COSTA, L.; SOUZA, A.; SOUZA, F. An investigation of challenges in the machine learning lifecycle and the importance of MLOps: A survey. *In: Computer on the Beach*, 14, 30 mar. - 1 abr, 2023, **Anais** [...] Florianópolis - SC, 2023, p. 379-386.
- ARAÚJO, Everton Coimbra. Aprofundando em Flutter: **Desenvolva aplicações Dart com Widgets**. Google Books. 2021.
- ARMESTO, L.; AFONSO, T.; MAGALHÃES, D.; SANTOS, L. Python como Linguagem de Programação mais Neurointuitiva para Aprendizagem a Profissionais de Saúde - Revisão Integrativa Da Literatura. *In: Congresso Internacional Ciência e Sociedade*, 1, 2023, Teresina. **Anais** [...], Teresina: Galoá, 2023. Disponível em: <https://proceedings.science/cics-2023/trabalhos/python-como-linguagem-de-programacao-mais-neurointuitiva-para-aprendizagem-a-pro-2?lang=pt-br>. Acesso em: 12 set. 2024.
- ARTZI N.; SHILO, S.; HADAR, E.; ROSSMAN, H.; BARBASH-HAZAN, S.; BEN-HAROUSH, A.; BALICER, R.; FELDMAN, B.; WIZNITZER, A. Prediction of Gestational Diabetes Based on Nationwide Electronic Health Records. **Nature Medicine**, v. 26, n. 1, p. 71-76, 2020. Disponível em: <https://www.nature.com/articles/s41591-019-0724-8>. Acesso em 14 set. 2024.
- AWARE, 2023. **Scikit-Learn: Uma Ferramenta para Análise de Dados e Machine Learning**. Disponível em: <https://awari.com.br/scikit-learn-2/>, Acesso em: 12 out. 2024.
- BEZERRA, F. **Desenvolvimento Nativo vs Ionic vs React Native: uma análise comparativa do suporte à acessibilidade em Android**. 2021. Trabalho de Conclusão de Curso (Graduação em Computação) - Universidade Federal do Ceará, Fortaleza, 2021. Disponível em: https://repositorio.ufc.br/bitstream/riufc/58979/1/2021_tcc_fsrbezerra.pdf. Acesso em: 12 out. 2024.
- BEZERRA, T. Saúde na adolescência: A importância do pré-natal no contexto da gravidez precoce. **Publicações**, 2023.
- BRASIL. Agência Nacional de Saúde Suplementar. **Taxa de Consultas de Pré-Natal (PESO 2)**. Brasília, DF: Agência Nacional de Saúde Suplementar, 2024a. Disponível em: <https://www.gov.br/ans/pt-br/assuntos/informacoes-e-avaliacoes-de-operadoras/1.2.TaxadeConsultasdePrNatal.pdf>. Acesso em: 30 maio 2024.

BRASIL. Ministério da Saúde. **Estratégia de Saúde Digital para o Brasil 2020-2028**. 1. ed. Brasília, DF: Ministério da Saúde, 2020. Disponível em: https://bvsms.saude.gov.br/bvs/publicacoes/estrategia_saude_digital_Brasil.pdf. Acesso em: 12 set. 2024.

BRASIL. Ministério da Saúde. **Importância do Pré-Natal**. Brasília, DF: Ministério da Saúde, 2016. Disponível em: <https://bvsms.saude.gov.br/importancia-do-pre-natal/>. Acesso em: 14 jun. 2024.

BRASIL. Ministério da Saúde. **Pré-Natal**. Brasília, DF: Ministério da Saúde, 2024b. Disponível em: <https://www.gov.br/saude/pt-br/assuntos/saude-de-a-a-z/g/gravidez/pre-natal>. Acesso em: 25 maio. 2024.

BRASIL. Ministério da Saúde. **Sistema de Informação em Saúde para a Atenção Básica**. 2024c. Brasília, DF: Ministério da Saúde. Disponível em: <https://sisab.saude.gov.br/paginas/acessoPublico/relatorio/indicadores/IndicadorPrenatal.xhtml>. Acesso em: 2 jun. 2024.

CERSONSKY, T.; AYALA, N.; PINAR, H.; DUDLEY, D.; SAADE, G.; SILVER, R.; LEWKOWITZ, A. Identifying risk of stillbirth using machine learning. **American Journal Obstetrics Gynecology**, v. 229, n. 3, p. 327.e1-327.e16, 2023. Disponível em: [https://www.ajog.org/article/S0002-9378\(23\)00409-X/abstract](https://www.ajog.org/article/S0002-9378(23)00409-X/abstract). Acesso em: 14 out. 2024.

CHARLES, N.; YOUNT, S.; MORGAN, A. Comfort over Pain in Pregnancy. **Pain Management Nursing**, v. 17, n.3, p.197-203, 2016. Disponível em: <https://www.sciencedirect.com/science/article/abs/pii/S152490421600076X>. Acesso em: 12 out. 2024.

CHEN, X; LIU, W. The Value of Python Programming in General Education and Comprehensive Quality Improvement of Medical Students Based on a Retrospective Cohort Study. **Journal of Healthcare Engineering**, v. 2022, p. 1-8, 2022. Disponível em: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC9050249/>. Acesso em: 12 set. 2024.

DOMINGOS, P. **The Master Algorithm**: How the Quest for the Ultimate Learning Machine Will Remake Our World. New York: Basic Books, 2015.

FACELI, K.; LORENA, A.; GAMA, J.; CARVALHO, A. **Inteligência artificial**: uma abordagem de aprendizado de máquina. Rio de Janeiro: Grupo GEN, 2021.

FERREIRA, F.; VARÃO, R.; BOSELLI, M.; SANTOS, L.; MORET, M. Uso de Python para detecção de fake news sobre a covid-19: desafios e possibilidades. **RECIIS - Revista Eletrônica de Comunicação, Informação e Inovação em Saúde**, Rio de Janeiro, v. 16, n. 2, p. 266-280, abr./jun. 2022.

GANDHEWAR, N.; SHEIKH, R. Google android: An emerging software platform for mobile devices. **International Journal on Computer Science and Engineering, Citeseer**, v. 1, n. 1, p. 12–17, 2010. Disponível em: https://www.researchgate.net/publication/313558348_Google_android_An_emerging_software_platform_for_mobile_devices. Acesso em: 27 set. 2024.

GAO C.; OSMUNDSON, S.; YAN, X.; EDWARDS, D.; MALIN, B.; CHEN, Y. Learning to Identify Severe Maternal Morbidity from Electronic Health Records. **Studies in Health Technology and Informatics**, v. 264, p. 143-147, 2019. Disponível em: <https://ebooks.iospress.nl/publication/51965>. Acesso em: 15 set. 2024.

GASPAR, J.; REIS, Z.; OLIVEIRA, I.; DA SILVA, A.; DIAS, C. **Introdução à análise de dados em saúde com Python** [livro eletrônico]. Belo Horizonte, MG: Biblioteca J. Baeta Vianna : Universidade Federal de Minas Gerais, 2023. Disponível em: <https://docs.bvsalud.org/biblioref/2023/06/1437637/introducao-a-analise-de-dados-em-saude-com-python-ciia-saude.pdf>. Acesso em: 13 set. 2024.

GOES, E.; RAMOS, D.; FERREIRA, A. **Sem deixar ninguém para trás: gravidez, maternidade e violência sexual na adolescência**. Bahia: Fundação Oswaldo Cruz, 2023. Disponível em: <https://brazil.unfpa.org/sites/default/files/pub-pdf/cartilha-unfpa-digital.pdf>. Acesso em: 28 maio 2024.

GRUS, Joel. **Data science do zero**. Alta books, 2016.

GUO Z.; YANG, F.; ZHANG, J.; ZHANG, Z.; LI, K.; TIAN, Q.; HOU, H.; Xu, C.; LU, Q.; REN, Z.; YANG, X.; LV, Z.; WANG, K.; YANG, X.; WU, Y.; YANG, X. Whole-Genome Promoter Profiling of Plasma DNA Exhibits Diagnostic Value for Placenta-Origin Pregnancy Complications. **Advanced Science**, v. 7, n.7, p. 1901819, 2020. Disponível em: <https://onlinelibrary.wiley.com/doi/full/10.1002/advs.201901819>. Acesso em: 14 nov. 2024.

GUPTA, P.; BAGCHI, A. Data Manipulation with Pandas. *In: Essentials of Python for Artificial Intelligence and Machine Learning*. Cham: Springer Nature Switzerland, 2024, p. 197-205,

HOLMES, W.; BIALIK, M.; FADEL, C. **Artificial Intelligence in Education** – Promises and Implications for Teaching and Learning. Boston: The Center for Curriculum Redesign, 2019.

JHEE J.; LEE, S.; PARK, Y.; LEE, S. E.; KIM, Y.; KANG, S.; KWON, J-Y.; PARK, J. Prediction Model Development of Late-Onset Preeclampsia Using Machine Learning-Based Methods. **PLoS One**, v. 14, n. 8, p. e0221202, 2019. Disponível em: <https://pubmed.ncbi.nlm.nih.gov/31442238/>. Acesso em: 14 out. 2024.

KALINOWSKI, M.; ESCOVEDO, T.; VILLAMIZAR, H.; LOPES, H. **Engenharia de software para ciências de dados: um guia de boas práticas com ênfase em construção de sistemas de machine learning**, 1. ed., São Paulo: Aovs Sistemas de Informática, 2023.

KAUFMAN, D. **Desmistificando a inteligência artificial**. São Paulo: Grupo Autêntica, 2022. E-book. Disponível em: <https://app.minhabiblioteca.com.br/#/books/9786559281596/>. Acesso em: 8 jul. 2024.

KHATIBI T.; KHEYRIKOOCHAKSARAYEE, N.; SEPEHRI, M. Analysis of Big Data for Prediction of Provider-Initiated Preterm Birth and Spontaneous Premature Deliveries and Ranking the Predictive Features. **Archives of Gynecology and Obstetrics**, v. 300, n. 6, p. 1565-1582, 2019. Disponível em:

<file:///C:/Users/Beatriz%20Moutinho/OneDrive/%C3%81rea%20de%20Trabalho/Downloads/s00404-019-05325-3.pdf>. Acesso em: 14 set. 2024.

KNOX, J.; WILLIAMSON, B.; BAYNE, S. Machine behaviourism: future visions of 'learnification' and 'datafication' across humans and digital technologies. **Learning, Media and Technology**, v. 45, n.1, p. 31-45, 2020. Disponível em: <https://www.tandfonline.com/doi/full/10.1080/17439884.2019.162325>. Acesso em: 17 set. 2024.

LI Y.; SHEN, X.; YANG, C.; CAO, Z.; DU, R.; YU, M.; WANG, J.; WANG, M. Novelelectronic health records applied for prediction of pre-eclampsia: Machine-learning algorithms. **Pregnancy Hypertension**, v, 26, p. 102-109, 2021. Disponível em: <https://pubmed.ncbi.nlm.nih.gov/34739939/>. Acesso em: 14 nov. 2024.

LIU, M.; YANG, X.; CHEN, G.; DING, Y.; SHI, M.; SUN, L.; HUANG, Z.; LIU, J.; LIU, T.; YAN, R.; LI, R. Development of a prediction model on preeclampsia using machine learning-based method: a retrospective cohort study in China. **Frontier in Physiology**, v.13, p. 896969, 2022. Disponível em: <https://pubmed.ncbi.nlm.nih.gov/36035487/>. Acesso em: 15 nov. 2024.

LOBO, L. Inteligência artificial, o futuro da medicina e a educação médica. **Revista Brasileira de Educação Médica**, v. 42, n. 3, p. 3-8, 2018. Disponível em: <https://pesquisa.bvsalud.org/portal/resource/pt/biblio-958613>. Acesso em: 12 ago. 2024.

MACIEL, B.; DE CARVALHO, I.; MENDES, L.; DA SILVA, K.; LANTMANN, O.; DE CARVALHO, H.; DE CARVALHO, G. Ferramentas de Inteligência Artificial. *In: Encontro Internacional de Gestão, Desenvolvimento e Inovação*, v. 7, n. 1, 15 nov. 2024.

MACKENZIE, A. The production of prediction: What does machine learning want? **European Journal of Cultural Studies**, v. 18, n. 4-5, p. 429-445, 2015. Disponível em: <https://journals.sagepub.com/doi/abs/10.1177/1367549415577384?journalCode=ecsa>. Acesso em: 14 set. 2024.

MALACOVA E.; TIPPAYA, S.; BAILEY, H.; CHAI, K.; FARRANT, B.; GEBREMEDHIN, A.; LEONARD, H.; MARINOVICH, M.; NASSAR, N.; PHATAK, A.; RAYNES-GREENOW, C.; REGAN, A.; SHAND, A.; SHEPHERD, C.; SRINIVASJOIS, R.; TESSEMA, G.; PEREIRA, G. Stillbirth Risk Prediction Using Machine Learning for a Large Cohort of Births from Western Australia, 1980-2015. **Scientific Reports**, v. 10, n. 1, p. 5354, 2020. Disponível em: <https://doi.org/10.1038/s41598-020-62210-9>. Acesso em: 14 out. 2024.

MARTINS, E.; ROCHA, L.; ARAÚJO, A.; TAVARES, T.; BARBOSA, R.; PINHEIRO, A. The effect of acupuncture on the relief of physical and emotional discomfort during pregnancy. **Revista de Pesquisa: Cuidado é Fundamental**. v. 12. n.1. p.227-232. 2020. Disponível em: https://www.researchgate.net/publication/342844342_The_effect_of_acupuncture_on_the_relief_of_physical_and_emotional_discomfort_during_pregnancy. Acesso em 10 set. 2024.

MCFARLAND, A. Bibliotecas Phyton. **10 melhores bibliotecas Python para aprendizado de máquina e IA12**. Unite.AI, 2024. Disponível em: <https://www.unite.ai/pt/10-melhores-bibliotecas-python-para-aprendizado-de-m%C3%A1quina-ai/>. Acesso em: 12 nov. 2024.

MIRA, J.; QUITO, R.; CAMPEÃO, A.; MOLERO, T.; HIPÓLITO, R.; FRIAS, A. Métodos não farmacológicos de controlo da dor no trabalho de parto: revisão narrativa de literatura. *In*: FRIAS, A.; AGOSTINHO, C. (org.). **A Obra Prima: a arte de cuidar no início da vida**. Guarujá. São Paulo: Editora Científica Digita, 2021. cap.8. p. 95-110.

MITCHELL, T. **Machine Learning**. New York: McGraw Hill, 1997

MOURA, L.; CAMARGO, G. **Impacto econômico e social do Android no Brasil**. Bain & Company, 2019. Disponível em: https://www.bain.com/contentassets/20e0815cfd784b4a8dead63475b42380/v02_b-impactos-do-android-no-brasil.pdf. Acesso em: 13 set. 2024.

NASCIMENTO NETO, C.; BORGES, K.; PENINA, P.; PEREIRA, A. Inteligência artificial e novas tecnologias em saúde: desafios e perspectivas. **Brazilian Journal of Development**, v. 6, n. 2, p. 9431–9445, 2020. Disponível em: <https://ojs.brazilianjournals.com.br/ojs/index.php/BRJD/article/view/7210/6282>. Acesso em: 13 jul. 2024.

NENÉ, M.; MARQUES, R.; BATISTA, M. **Enfermagem de Saúde Materna e Obstétrica**. (ebook). Lidel. 2020.

NILSSON, N. **The Quest for Artificial Intelligence – A History of Ideas and Achievements**. Nova York: Cambridge University Press, 2010.

NOGUEIRA, A.; TIBIRIÇA, C.; MOURA, P.; MARQUES, W. O uso da inteligência artificial como ferramenta de apoio à gestão das ações em saúde de Goiás. **Revista Científica da Escola Estadual de Saúde Pública de Gestão "Cândido Santiago"**, v. 8, p. 1-5, 2022. Disponível em: <https://www.revista.esap.go.gov.br/index.php/resap/article/view/390/229>. Acesso em: 18 jul. 2024.

OLIVEIRA, A.; LIMA, E; CARIDADE, E. O Uso dos Framework Flutter e NEST.Js para Desenvolvimento de um Front-End e um Back-End de uma aplicação de Help Desk. **Revista Ibero-Americana de Humanidades, Ciências e Educação**, v. 8, n. 11, p. 1766–1786, 2022. Disponível em: <https://doi.org/10.51891/rease.v8i11.777>. Acesso em: 12 dez. 2024.

PALLASMAA, N.; EKBLAD U.; GISSLER M. Severe maternal morbidity and the mode of delivery. **Acta Obstetricia et Gynecologica**. v. 87, n. 6, p. 662-668, 2008. Disponível em: <https://obgyn.onlinelibrary.wiley.com/doi/full/10.1080/00016340802108763>. Acesso em: 13 out. 2024.

PATEL, R.; MURPHY, D. Forceps delivery in modern obstetric practice. **BMJ**, v. 328, n. 7451, p.1302-1305, 2004. Disponível em: <https://pmc.ncbi.nlm.nih.gov/articles/PMC420176/pdf/bmj32801302.pdf>. Acesso em 13 out. 2024.

PEREIRA, A. **Vivência da gravidez e importância atribuída pelas mães à consulta de enfermagem**: um estudo de caso numa unidade de saúde familiar. 2013. Dissertação (Mestrado em Educação para a Saúde) – Faculdade de Medicina, Universidade do Porto, Porto, 2013. Disponível em: <https://repositorio-aberto.up.pt/handle/10216/72231>. Acesso em: 12 out. 2024

PETROVSKIY M. Outlier Detection Algorithms in Data Mining Systems. **Program and Computer Software**, v. 29, n. 4, p. 228-237, 2003. Disponível em: https://www.researchgate.net/publication/227252790_Outlier_Detection_Algorithms_in_Data_Mining_Systems. Acesso em 12 out. 2024.

QUIXABEIRA, C.; GOMES, M.; FLOR, I.; SANTOS, A.; BATISTA, A.; OLIVEIRA, C.; NASCIMENTO, J. Métodos de inteligência artificial na predição e diagnóstico precoces de complicações na gravidez. **Revista Eletrônica Acervo Saúde**, v. 24, n. 6, p. 1-13, 2024. Disponível em: <https://acervomais.com.br/index.php/saude/article/view/16231/8831>. Acesso em: 14 nov. 2024.

RITTENHOUSE, K.; VWALIKA, B.; KEIL, A.; WINSTON, J.; PRICE, J.; KAPASA, M.; MUBAMBE, M.; BANDA, V.; MUUNGA, W.; STRINGER, J. Improving Preterm Newborn Identification in Low-Resource Settings with Machine Learning. **PLoS One**, v. 14, n. 2, e0198919, 2019. Disponível em: <https://pubmed.ncbi.nlm.nih.gov/30811399/>. Acesso em: 14 nov. 2024.

ROSA, C.; SILVEIRA, D.; COSTA, J.; Fatores associados à não realização de pré-natal em município de grande porte. **Revista Saúde Pública**, v. 48, n. 6, p. 977-984, 2014. Disponível: <https://www.scielo.br/j/rsp/a/8ck76857qYSznT35jfCp7Qy/?lang=pt#:~:text=A%20maioria%20dos%20estudos%20publicados,sa%C3%BAdade%20e%20de%20suporte%20social>. Acesso em: 18 dez. 2024;

SHEARER, E. Cesarean section: medical benefits and costs. **Social Science & Medicine**. v. 37, n. 10, p. 1223-1231, 1993. Disponível em: <https://pubmed.ncbi.nlm.nih.gov/8272901/>. Acesso em: 13 dez. 2024.

SHORTLIFFE E; CIMINO J. (ed.). **Biomedical Informatics: Computer Applications in Health Care and Biomedicine**, 3. ed. New York, NY: Springer; 2006. Disponível em: <http://link.springer.com/10.1007/0-387-36278-9>. Acesso em: 12 nov. 2024.

SICSU, A.; SAMARTINI, A.; BARTH, N. **Técnicas de machine learning**. São Paulo: Editora Blucher, 2023.

SILVA, F.; BRITO, R.; CARVALHO, J.; LOPES, T. Using acupressure to minimize discomforts during pregnancy. **Revista Gaúcha de Enfermagem**. v. 37. n. 2. p. 1-8, 2016. Disponível em: <http://dx.doi.org/10.1590/1983-1447.2016.02.54699>. Acesso em: 12 out. 2024.

SILVA, F.; LENZ, M.; FREITAS, P.; SANTOS, S. **Inteligência artificial**. Porto Alegre: Grupo A, 2018.

SILVA, J.; MEDEIROS, F.; MOURA, F.; BESSA, W.; BEZERRA, E. Uso das Tecnologias de Informação e Comunicação no Curso de Medicina da UFRN. **Revista Brasileira de Educação Médica**, v. 39, n. 4, p. 537-541, 2015. Disponível em: <https://www.scielo.br/j/rbem/a/pcg9J4jhSbxs9CWRjftshxP/>. Acesso em: 18 out. 2024.

SOARES, R.; PEREIRA, I.; FRAZÃO, M.; DUQUE, M.; SANTOS, J.; DUQUE, R.; PÁDUA, D.; MARTINS, J.; PEIXOTO, J.; ACÁCIO, M.; GALVÃO, A.; ARAÚJO, S. O uso da inteligência artificial na medicina: aplicações e benefícios.

Research, Society and Development, v. 12, n. 4, p. e5012440856, 2023. Disponível em: https://www.researchgate.net/publication/369621299_O_uso_da_inteligencia_artificial_na_medicina_aplicacoes_e_beneficios. Acesso em: 12 jul. 2024.

STEFFEN, César. A tela dos dispositivos Android: um percurso de pesquisa sobre design responsivo. **Projética, Londrina**, v. 11, n. 2, p. 15-34, 2020. Disponível em: <https://ojs.uel.br/revistas/uel/index.php/projetica/article/view/29897/27958>. Acesso em: 21 nov. 2024.

SUN H.; QU, H.; CHEN, L.; WANG, W.; LIAO, Y.; ZOU, L.; ZHOU, Z.; WANG, X.; ZHOU S. Identification of Suspicious Invasive Placentation Based on Clinical MRI Data Using Textural Features and Automated Machine Learning. **European Radiology**, v. 29, n. 11, 6152-6162, 2019. Disponível em: <https://link.springer.com/article/10.1007/s00330-019-06372-9>. Acesso em: 14 nov. 2024.

TAN, P.-N.; STEINBACH, M.; KUMAR, V. **Introduction to Data Mining**. Boston: Addison Wesley, 2006.

WATANABE M.; EGUCHI, A, SAKURAI, K, YAMAMOTO, M, MORI, C. Prediction of gestational diabetes mellitus using machine learning from birth cohort data of the Japan Environment and Children's Study. **Scientific Reports**, v. 13, n. 1, p. 17419, 2023. Disponível em: <https://www.nature.com/articles/s41598-023-44313-1>. Acesso em: 22 nov. 2024.

WHO. **Global strategy on digital health 2020-2025**. World Health Organization. 2020. Disponível em: <https://apps.who.int/iris/handle/10665/344249>. Acesso em: 12 nov. 2024.

WHO. **Maternal mortality**. 26 abr. 2024. Disponível em: <https://www.who.int/news-room/fact-sheets/detail/maternal-mortality>. Acesso em: 12 set. 2024.

WHO. **Trends in maternal mortality 2000 to 2017**: estimates by WHO, UNICEF, UNFPA, World Bank Group and the United Nations Population Division. Geneva: World Health Organization; 2019. Disponível em: <https://www.unfpa.org/featured-publication/trends-maternal-mortality-2000-2017>. Acesso em: 12 set. 2024.

ZAMMETTI, Frank. **Flutter na prática**. Editora Novatec, 2020.

ZHANG, H.; DAI, J.; ZHANG, W.; SUN, X.; SUN, Y.; WANG, L.; LI, H.; ZHANG, J. Integration of clinical demographics and routine laboratory analysis parameters for early prediction of gestational diabetes mellitus in the Chinese population. **Frontiers in Endocrinology**, v. 14, p. 1216832, 2023. Disponível em: <https://pubmed.ncbi.nlm.nih.gov/37900122/>. Acesso em: 3 dez. 2024.